


**UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS**  
(Universidad del Perú, Decana de América)

**FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMÁTICA**  
**E.A.P. DE INGENIERÍA DE SOFTWARE**



**Diseño de una arquitectura basado en redes neuronales para  
generar un modelo predictivo de clasificación del rendimiento  
académico universitario**

TESIS PREGRADO

**AUTOR**

Machuca Pajuelo Manuel Omar

**ASESOR**

Calderón V. Hugo David

**Lima – Perú**

**2017**

CAPÍTULO I: INTRODUCCIÓN	5
1.1 Problema de investigación	5
1.1.1 Planteamiento e importancia del problema	5
1.1.2 Identificación y análisis del problema	7
1.1.3 Formulación del problema	8
1.2 Fundamentación Teórica	8
1.2.1 El Rendimiento Académico	8
a) La tasa de éxito	9
b) La tasa de repitencia	9
c) La tasa de deserción	10
1.2.2 La Deserción universitaria en el Perú	10
1.2.3 Evaluación del rendimiento académico	12
1.2.4 Red Neuronal Artificial	16
1.3 Motivación de la propuesta	23
1.4 Objetivos	23
1.4.1 Objetivo general	23
1.4.2 Objetivos específicos	23
CAPÍTULO II: ESTADO DEL ARTE	24
2.1 Prefacio	24
2.2 Algoritmos clasificadores para generar modelos de predicción del rendimiento académico	26
2.3 Metodologías para definir una arquitectura de predicción de rendimiento académico	32
CAPÍTULO III: APORTE	40
3.1 Descripción	40
3.1.1 Componentes del aporte	40
3.1.2 Modelo del aporte	42
3.1.3 Fases para la creación del aporte	43
1) Extracción y preparación de datos	43
2) Entrenamiento de la red neuronal	44
3) Construcción del entorno para realizar el entrenamiento de la red neuronal	51
4) Construcción del aplicativo de predicción de rendimiento académico universitario	52
CAPITULO IV: DESARROLLO DE LA APLICACIÓN	56

4.1	Análisis de la solución	56
4.1.1	Entrevistas a estudiantes	56
4.1.2	Resultados de las entrevistas realizadas	56
4.1.3	Desarrollo de Historias de Usuario	57
4.1.4	Requerimientos funcionales	61
4.1.5	Velocidad de proyecto	62
4.1.6	Actores del software propuesto	62
4.2	Diseño de la solución propuesta	63
4.2.1.1	Procesos de la solución propuesta	63
4.2.2	Modelo de base de datos	65
4.2.3	Arquitectura del aplicativo web	65
4.2.4	Diagrama de despliegue del sistema	67
4.2.5	Interfaces graficas del sistema	68
CAPITULO V: RESULTADOS Y DISCUSIÓN		69
5.1	Resultados de entrenamiento de la red neuronal	69
5.2	Resultados de aplicativo web	73
REFERENCIA BIBLIOGRAFICAS		75

Figura 1: Árbol de problema del rendimiento académico universitario.....	7
Figura 2: Estructura de red neuronal multicapa .....	17
Figura 3: Arquitectura propuesta.....	42
Figura 4: Diseño de la red neuronal .....	44
Figura 5: Salidas de propagación hacia adelante.....	45
Figura 6: Error en capa de salida.....	47
Figura 7: Propagación hacia atrás .....	48
Figura 8: Retroceso del error a través de las gradientes .....	50
Figura 9: Arquitectura del sistema .....	55
Figura 10: Ámbitos de evaluación de Sonar .....	55
Figura 11: Actores del sistema .....	62
Figura 12: BPM Proceso de clasificación .....	63
Figura 13: BPM Proceso de aprendizaje .....	64
Figura 14: Modelo de datos físico.....	65
Figura 15: Arquitectura del software .....	66
Figura 16: Diagrama de despliegue de la solución propuesta .....	67
Figura 17: Login del aplicativo .....	68
Figura 18: Página principal del aplicativo web .....	68
Figura 19: Presentación de una predicción de rendimiento por aplicativo .....	74

# CAPÍTULO I: INTRODUCCIÓN

## 1.1 Problema de investigación

### 1.1.1 Planteamiento e importancia del problema

En la realidad del Perú existen diversidad de problemas, problemas económicos, problemas políticos, problemas sociales, etc. De dichos problemas uno de los más críticos es la educación, y peor aún este problema se sigue afectando por la agudización de los niveles de pobreza en la que se encuentran la mayor parte de la población.

Informe sobre la educación peruana situación y perspectivas (Idel Vexler Talledo ex Viceministro de Educación (2004)). Así, es la educación la que permite construir consensos básicos de vida democrática y posibilita la integración social; es factor de reducción de desigualdades y sustento de la construcción de caminos de progreso: es base del crecimiento del bienestar con equidad y llave para la necesaria inserción en el mundo cambiante de nuestros días, la ciencia y la tecnología. Imaginar el país del mañana implica la tarea de educar desde hoy, porque son las personas las que promueven el progreso de un país, en la medida en que desarrollan una serie de habilidades y capacidades.

En la actualidad las universidades se encuentran en una etapa de grandes cambios, que son resultado de una serie de tendencias internacionales: la masificación y democratización de la educación superior, el aumento de la competencia por la captación de alumnos, el uso del conocimiento como factor de gran importancia en la producción, entre otras (Wooldridge, 2005). De estas tendencias, la más interesante y llamativa es la masificación de la educación terciaria (Thorne, 2000: 3). En efecto, la Organización de las Naciones Unidas para la Educación (UNESCO) reconoce que la segunda mitad del siglo XX pasará a la historia de la educación superior como su época de expansión más espectacular. De este modo, la información de la UNESCO (1998) indica que, a escala mundial, el número de estudiantes matriculados se multiplicó por más de seis desde 1960 (13 millones) hasta 1995 (82 millones).

Considero que para garantizar la calidad de la educación universitaria es urgente identificar y analizar el impacto de los factores o variables que influyen sobre el rendimiento académico.

Adicionalmente, Yolvi Ocaña Fernández (2011), afirma que el déficit en los aprendizajes previos que pueden ser atribuidos a la educación escolar (más si es una escuela básica tan diversa como la nuestra), no necesariamente implica que el estudiante carezca de potencial académico, pero dificulta el proceso de enseñanza-

aprendizaje y exige reformas en los procesos de admisión, así como en los diseños curriculares y la didáctica, para mejorar así el rendimiento académico y reducir la probabilidad de desaprobación en las asignaturas universitarias.

Los problemas de educación universitaria tienen diversas causas como ya se explicó, el rendimiento académico en las universidades no es el esperado por lo que es muy importante brindar soluciones que ayuden en este problema. Nuestro contexto de estudio será la Facultad de Ingeniería de Sistemas e Informática de la Universidad Nacional Mayor de San Marcos, en dicho centro de estudios superiores se han optado con algunas estrategias que permitan mejoras en la calidad de la educación, como convenios con otras universidades, nuevas mayas curriculares, campañas de reforzamientos y entre otros.

Existen problemas en cuanto a soluciones creadas para la predicción de rendimiento académico, se observó que existen aspectos que no se tomaron en cuenta.

Hamsa, Indiradevi, Kizhakkethottam (2016), explican cómo predecir el rendimiento académico de manera eficaz clasificando la información y generando un modelo predictivo, obteniendo resultados valiosos, las grandes cantidades de permite esto posible.

Según Wang, Harari, Hao, Zhou, y Campbell (2015). Indica como con la información de los Smartphone se puede realizar una predicción del rendimiento académico, con esto concluimos que también es posible realizar una predicción con información no común en los sistemas de aprendizaje en línea o sistemas de matrículas, en este caso información captada por sensores de los móviles. Primero resaltemos: existen estudios e investigaciones sobre la predicción del rendimiento académico, se utiliza técnicas de clasificador de datos, métodos estadísticos, minería de datos, algoritmos genéticos, métodos estadísticos entre otros.

Merchán, y Duarte (2015), Por el lado de las técnicas de predicción en el campo de estudio de rendimiento académico las redes neuronales se han utilizado como algoritmos para clasificación no supervisados y supervisados.

Santhosh Nagulan, Jegadheeswaran Selvaraj, Amarkarthik Arunachalam y Kaushik Sivanandam (2017). En donde una red neuronal artificial es utilizada para predecir el rendimiento de convertidores de energía.

En base a estos casos de éxito se propone el uso de redes neuronales artificiales en una arquitectura de Perceptron multicapas utilizando el algoritmo de Backpropagation debido a que necesitamos un aprendizaje constante encontrando los errores en las capas

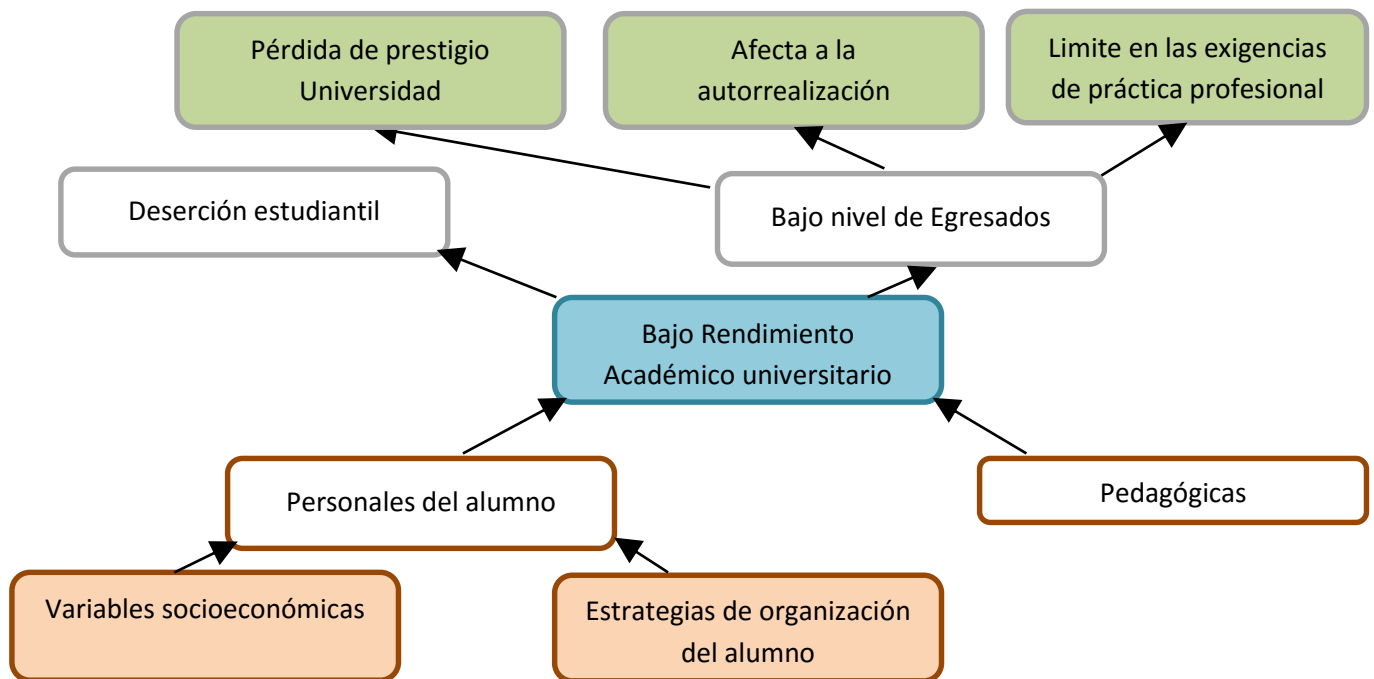
ocultas para realizar la predicción del rendimiento académico universitario y a la necesidad de ser una red neuronal supervisada.

Leonardo M. Reyneri y Enrica Filippi (1991). El autor uso el algoritmo de BP, se observó que debido a que la red es muy extensa el algoritmo tuvo muchas advertencias ya desde el planteo, se observó que converge muy despacio, por lo que para una red con el contexto que planteo no tendría aquellas advertencias.

Con la investigación presentada se espera obtener los resultados correctos de la predicción del rendimiento académico universitario, para que así los estudiantes tomen las acciones necesarias preventivas y así tener un óptimo desempeño en sus ciclos de estudio y por consiguiente la mejora del rendimiento académico.

### 1.1.2 Identificación y análisis del problema

Da acuerdo a Tonconi (2013). Indica las causas y consecuencia de un bajo rendimiento académico universitario, creando así este árbol de problemas estableciendo una jerarquía y relación.



**Figura 1: Árbol de problema del rendimiento académico universitario**

El árbol de problema está compuesto por el problema, las causas y consecuencias, las causas son de tipo Personales del alumno compuesta por variables socioeconómicas, y pedagógicas que externas al alumno, mientras que las consecuencias son la deserción estudiantil y un bajo nivel de los egresados.

El Bajo rendimiento académico posee diferentes causas, sin embargo en esta investigación se toma las causas de tipo “Personales del alumno”, y se utilizarán las variables del grupo de “Estrategias de organización del alumno” para la investigación, sin embargo para un trabajo futuro o mejora de la investigación las variables no utilizadas pueden ser de utilidad.

### **1.1.3 Formulación del problema**

Como generar un modelo predictivo del rendimiento académico universitario mediante el diseño de una arquitectura de perceptrón multicapa con backpropagation.

## **1.2 Fundamentación Teórica**

En esta sección trataremos acerca del rendimiento académico y la deserción estudiantil en el Perú, las causas de esta; también abordaremos el tema de lo que es su evaluación. Otro aspecto importante es hacer un contraste entre las redes neuronales biológicas y las artificiales, el cual será técnica utilizada para el modelo propuesto para la presente investigación.

### **1.2.1 El Rendimiento Académico**

Requena (1998), afirma que “el rendimiento académico es fruto del esfuerzo y la capacidad de trabajo del estudiante. De las horas de estudio, de la competencia y el entrenamiento para la concentración”.

El rendimiento académico como una forma específica o particular del rendimiento escolar es el resultado alcanzado por parte de los estudiantes que se manifiesta en la expresión de sus capacidades cognoscitivas que adquieren en el proceso enseñanza-aprendizaje, esto a lo largo de un periodo o año escolar.

De Natale (1990), afirma que “el aprendizaje y rendimiento implican la transformación del conocimiento, que se alcanza con la integración en una unidad diferente con elementos cognoscitivos y de estructuras ligadas inicialmente entre sí”.



Según el autor, el rendimiento académico es un conjunto de habilidades, destrezas, hábitos, ideales, aspiraciones, intereses, inquietudes, realizaciones que aplica el estudiante para aprender. El rendimiento académico es un indicador del nivel de aprendizaje alcanzado por el mismo, por ello, el sistema educativo brinda tanta importancia a dicho indicador. En tal sentido, el rendimiento académico se convierte en una tabla imaginaria de medida para el aprendizaje logrado en el aula, que constituye el objetivo central de la educación.

### **Factores del Rendimiento Académico**

De acuerdo a Chayña (2007). Los factores del rendimiento académico son: 1. Nivel intelectual. 2. Personalidad, 3. Motivación, 4. Las aptitudes, 5. Los intereses, 6. Hábitos de Estudio. 7. Autoestima.

### **Indicadores del Rendimiento Académico**

Los indicadores del rendimiento académico están constituidos por:

#### **a) La tasa de éxito**

Se asocia en primera instancia con un rendimiento académico alto, esto supone que, en la medida en que el rendimiento académico se expresa a través de las notas o puntuaciones asignadas al estudiante, tales notas se constituyen en el indicador principal del éxito. Sin embargo, si el éxito se identifica, no con el logro de objetivos instructivos específicos que están en la base de lo que normalmente se entiende como rendimiento académico, sí no con la consecución de las grandes metas o fines generales de la educación, tales como preparar para la vida (profesional, social, económica), es decir, la adaptación personal a las condiciones objetivas de la vida, incluyendo también la capacidad de modificar estas condiciones, el criterio de éxito se desplaza en el espacio y en el tiempo.

#### **b) La tasa de repitencia**

Se manifiestan según los factores académicos y son: Bajas calificaciones, pérdida de interés por los estudios, deficiente formación en la educación de acuerdo al nivel educativo, deficiente conocimiento sobre estilos y estrategias de aprendizaje y escasos recursos o materiales educativos.

### c) La tasa de deserción

Se manifiestan según los factores académicos y son: Bajas calificaciones, pérdida de interés por los estudios, deficiente formación en la educación de acuerdo al nivel educativo, deficiente conocimiento sobre estilos y estrategias de aprendizaje y escasos recursos o materiales educativos.

## 1.2.2 La Deserción universitaria en el Perú

La palabra deserción está ligada al verbo desertar, que significa abandonar, dejar o alejarse de algo. Entonces llevándolo al plano educativo, podemos decir que la deserción universitaria es el abandono de los estudios superiores por uno o varios motivos que afronta el alumno en pleno trayecto de su carrera universitaria.

### Principales causas de la deserción universitaria

Se analizaron varios factores por los cuales un estudiante deserta de sus estudios universitarios, entre los cuales podemos resaltar los siguientes: vocacional, económico, académico, personal, salud, adaptación y familiar, de estos factores los índices más altos apuntan al factor vocacional seguido del factor económico.

De acuerdo a Effer Apaza y Alberto Huamán (2014), explica los dos principales factores causantes de deserción universitaria:

- 1) **El aspecto Económico:** Los padres de familia, con la mejor intención de ofrecerles a sus hijos una buena educación, asumen un compromiso de pago de pensiones que muchas veces está fuera de su alcance. Cuando ya no es posible seguir manteniendo esta obligación, sus hijos deben abandonar la universidad, con la consecuente frustración para toda la familia, y en especial para el joven que ve truncadas las posibilidades de su desarrollo profesional.
- 2) **La Falta de Vocación por la carrera elegida:** Otro elemento presente en esta realidad es que muchos estudiantes no tienen claro si realmente tienen vocación por lo que estudian. Muchos chicos ingresan a la universidad con la esperanza que realmente disfrutaran la profesión elegida; pero luego sufren una profunda decepción al descubrir que lo que estudian no les agrada o no es lo que esperaban. Se hizo una investigación

sobre la deserción de los estudiantes de la Universidad Peruana Unión, sede Tarapoto, y este fue el resultado:

### **Cantidad de alumnos matriculados por ciclo en la Universidad Unión**




Figura 2: alumnos matriculados por año

Se observa que el año 2009 se obtuvieron 417 alumnos matriculados, que luego para el segundo ciclo bajo a 384 estudiantes, teniendo un índice de deserción del 7,9%. También vemos que en el año 2010 se observa un total de 518 estudiantes, y para el segundo ciclo del mismo año, el número total de estudiantes matriculados fue de 487. Lo cual nos da un índice de deserción del 6% para el año 2010. Finalmente, en el año 2011, el número de matriculados fue de 763 estudiantes, luego para el segundo ciclo el número de matriculados fue de 762, lo cual muestra una deserción mínima de 0.1%.

### **Enfoques del análisis de la deserción universitaria**

De acuerdo a Braxton (1997), los enfoques del análisis de la deserción pueden ser agrupadas en cinco grandes categorías, dependiendo del énfasis que otorgan las variables explicativas, ya sean individuales, institucionales o del medio familiar. De esta manera es posible reconocer los siguientes enfoques:

- a) **Psicológicos:** El rasgo de la personalidad es lo que diferencia a los estudiantes que terminan sus estudios regulares de aquellos que no lo logran, cuyas bases fundamentales fueron los procesos psicológicos relacionados con la integración académica y social.

- b) **Económicos:** Según investigaciones en este enfoque se puede distinguir dos modelos:
- a. **Costo/Beneficio:** Consiste en que cuando los beneficios sociales y económicos asociados a los estudiantes son percibidos como mayores que los derivados por actividades alternas; por lo cual el estudiante opta por permanecer en la universidad.
  - b. **Focalización de Subsidio:** Consiste en la entrega de subsidios que constituyen una forma de influir sobre la deserción. Estos subsidios están dirigidos a los grupos que presentan limitaciones reales para costear sus estudios.
- c) **Sociológicos:** Los modelos sociológicos enfatizan respecto a la influencia en la deserción de factores externos al individuo, adicionales a los psicológicos, se basó en el modelo suicida indicando que la deserción es el resultado de la falta de integración de los estudiantes en el entorno de la educación superior; aduce que el medio familiar es una de las muchas fuentes que expone a los estudiantes a influencias, expectativas y demandas, las que a su vez afectan su nivel de integración social en la universidad; la congruencia normativa actúa directamente sobre el rendimiento académico, el desarrollo intelectual, el apoyo de pares y la integración social.
- d) **Organizacionales:** Este modelo de análisis sostiene que la deserción depende de las cualidades de la organización en la integración social y más, particularmente, en el abandono de los estudiantes que ingresan a ella. Este enfoque está altamente relacionado a la calidad de la docencia y de la experiencia de aprender en forma activa por parte de los estudiantes en las aulas, las cuales afectan positivamente la integración social del estudiante.

### 1.2.3 Evaluación del rendimiento académico

Víctor García Hoz (1974). En el contexto del modelo de evaluación que acaba de exponerse, el rendimiento de los alumnos se inserta en el grupo de los resultados, pero pronto se va a ver que está en estrecha relación también con los antecedentes y el proceso mismo de la educación.

**Dos nociones de rendimiento. Rendimiento suficiente y rendimiento satisfactorio**

Víctor García Hoz (1974). En la práctica usual el rendimiento de los alumnos se valora en función de unos objetivos señalados con más o menos precisión. Se evalúa el rendimiento de todos los alumnos constitutivos de un conjunto, un curso escolar, por ejemplo, en relación con un «nivel» de conocimientos, previamente establecido: como algo que debe ser alcanzado y sobrepasado por cualquier alumno si éste ha de ser objeto de una evaluación positiva.

El rendimiento así considerado existe, como se acaba de decir, en relación con un conjunto o con una abstracción. Cuando se habla de los estudiantes de tal o cuál curso se está haciendo referencia directa al conjunto; cuando se habla de «el estudiante medio» se está haciendo referencia a una abstracción. En esta noción de rendimiento no tiene cabida la consideración personal de cada uno de los estudiantes. La evaluación positiva es tanto como afirmar que un conjunto ha dado un rendimiento suficiente: la evaluación negativa es la afirmación de un rendimiento insuficiente. Suficiencia o insuficiencia son afirmaciones que arrancan de la comparación del nivel alcanzado por un estudiante cualquiera y el nivel establecido previamente.

### **Evaluación continúa**

Víctor García Hoz (1974). Entre los antecedentes y el resultado está el proceso mismo de la educación. Si el rendimiento se entiende no como una especie de aparición repentina al final de un período de actividad, sino como algo que constantemente se está produciendo, su evaluación es susceptible de ser realidad de un modo constante.

A esta idea responde la evaluación continua en virtud de la cual la evaluación del rendimiento se proyecta en el proceso mismo de la educación. Como expresión, la «evaluación continua» es una invención actual. Pero de hecho la evaluación continua ha venido siendo realizada desde siempre por aquellos buenos profesores que, teniendo un corto número de alumnos, a través de la actividad docente misma, explicación, diálogo y trabajo, se dan cuenta de en qué medida progresan sus alumnos y no necesitan hacer un examen al final del curso para discernir la calificación adecuada a cada uno de ellos.

El problema se complica en nuestros tiempos porque hemos de considerar como un sueño el que un profesor atienda solamente a un número reducido de alumnos, cosa que por otra parte en las condiciones de la sociedad actual llevaría a una educación defectuosa. Por otra parte, la educación no es sólo instrucción de aprendizaje, sino que es desarrollo de toda la personalidad del

sujeto, por lo cual es menester evaluar no solamente lo que el estudiante sabe, sino también los hábitos de trabajo intelectual, de convivencia social, las aptitudes técnicas, la madurez emocional, el desarrollo biológico y, en fin, todas las manifestaciones de la personalidad del hombre.

La técnica de la evaluación continua tiene tres bases fundamentales: La observación de la actividad o comportamiento discente de los estudiantes, el análisis de las tareas realizadas y las pruebas objetivas de diagnóstico.

### **Rendimiento y predicción**

Víctor García Hoz (1974). En el terreno educativo toda evaluación del rendimiento implica una hipótesis predictiva, explícita o implícita.

En efecto, para hacer la evaluación suficiente o insuficiente es menester que previamente se hayan determinado de antemano los objetivos o el nivel que debe ser alcanzado por los estudiantes pertenecientes a un determinado conjunto. Cuando una institución escolar tiene bien programadas sus actividades los objetivos o nivel están explícitamente mencionados antes de comenzar la actividad escolar. Cuando la institución escolar opera siguiendo unas orientaciones generales y sin una programación precisa, entonces los objetivos o nivel los establece cada profesor o grupos de profesores; pero, aunque este establecimiento no sea explícito, realmente está operando antes de que se empiece la evaluación.

### **Las técnicas de la predicción. Predictores y criterio**

Víctor García Hoz (1974). El problema técnico de la predicción del rendimiento se suele solucionar corrientemente tomando como punto de partida la correlación existente entre el rendimiento y las características personales que se consideran ligadas a él. El caso más simple de predicción está en el uso de la relación existente entre rendimiento y una característica personal, la capacidad mental, por ejemplo. En este caso, rendimiento y capacidad mental son dos variables entre las cuales hay una cierta relación. Si se tiene un exacto conocimiento de la puntuación de un estudiante en una de las variables, se puede utilizar el conocimiento de su relación para predecir la puntuación que alcanzará en la otra variable.

### **Dificultades y riesgos de la evaluación del rendimiento**

Víctor García Hoz (1974). Es frecuente la queja de los profesores que se enfrentan con la necesidad de evaluar porque se hallan ante dificultades que en ocasiones no pueden salvar. Estas se pueden reducir a dos tipos: La dificultad de evaluar el rendimiento de los estudiantes en función de unos objetivos cuya posibilidad de evaluación no se ve con claridad y la dificultad de apreciar con objetividad un trabajo complejo que ofrece muchos aspectos y una gran diversidad de elementos.

De las dos dificultades mencionadas me parece fundamental la primera, cuya solución implica la formulación de objetivos claramente definidos en términos de conducta expresiva, de tal suerte que puedan ser evaluables. Para hacer posible la evaluación debe prescindirse, al formular los objetivos, de utilizar palabras que se refieran a procesos internos no observables directamente y expresarlos más bien en forma de actividades cuya manifestación externa haga posible la evaluación. Así al formular los objetivos deben éstos expresar claramente qué es lo que un alumno tiene que ser capaz de hacer para mostrar su dominio de los conocimientos o destrezas adquiridos, así como de la expresión externa de actitudes. De acuerdo a Víctor García Hoz (1974). Por esta razón se evitarán términos generales, tales como comprender, apreciar, y ser sustituidos por las correspondientes manifestaciones externas, tales como explicar, describir, resolver.

### **Una exigencia de la personalización educativa. La autoevaluación**

Víctor García Hoz (1974). En el ámbito de la educación personalizada, uno de cuyos fundamentos es la consideración de la persona del estudiante como principio de actividad, ha de plantearse el problema de la autoevaluación. De acuerdo a Lindvall, C. M., y Cox, R. C (1970). Cada estudiante debe ser capaz de hacer un diagnóstico válido de sus posibilidades y limitaciones, así como de su propio progreso, de suerte que pueda asumir la responsabilidad para plantear y desarrollar las actividades más convenientes para él.

Por esta razón, tanto al fijar los medios o instrumentos de evaluación, así como al programar las actividades de los estudiantes, debe plantearse el problema concreto de las actividades que los estudiantes han de estudiar para autoevaluarse y los medios necesarios que han de ser utilizados para ello.

La autoevaluación es eficaz si el estudiante puede llevar el registro de su propio adelanto. Desde un punto de vista radicalmente educativo, los resultados del rendimiento de un escolar no tienen por qué ser comparados con el rendimiento

de los otros, pero sí con la asignación de objetivos al propio estudiante y con su progreso. Esto no quiere decir que carezca de sentido el que a un estudiante se le facilite el conocimiento de su situación en el grupo; pero sin comparaciones personales que suelen tener efectos predominantemente negativos.

#### **1.2.4 Red Neuronal Artificial**

##### **La aplicación de las redes Neuronales**

Basogain (2012). En la actualidad gracias a diversos grupos de investigación repartidos por universidades de todo el mundo, las redes neuronales han alcanzado una madurez muy aceptable y se usan en todo tipo de aplicaciones. Algunas de las áreas de aplicación son las siguientes:

- Análisis y Procesado de señales
- Reconocimiento de Imágenes
- Control de Procesos
- Filtrado de ruido
- Robótica
- Procesado del Lenguaje
- Diagnósticos médicos

De acuerdo a Numberger (2013). También podemos citar algunas aplicaciones industriales como:

- Equalizars: Para el procesamiento de señales, que se usan como procesadores programables de redes neuronales para la igualación de canales digitales.
- Neuropipe: Para la inspección de gaseoductos y oleoductos, en busca de corrosión y averías regularmente.
- Soft sensors: Para medir variables del proceso industrial los cuales no pueden ser medidos “online”. La ventaja es que habrá una estimación temprana de la calidad del proceso con costes bajos.

##### **Neurona Artificial**

De acuerdo a Sobrevilla (2010). Una neurona Artificial, es una unidad elemental de procesamiento de información para cualquier modelo de red neuronal. La neurona artificial, equivalente a una neurona biológica, intenta imitar los aspectos de esta en cuanto a su comportamiento y funcionamiento. De este modo se disponen de unas entradas y salidas, como en las neuronas biológicas, que transmitirán valores, bien reales o binarios de una neurona a otra, en vez de señales electroquímicas. Una red neuronal puede verse como

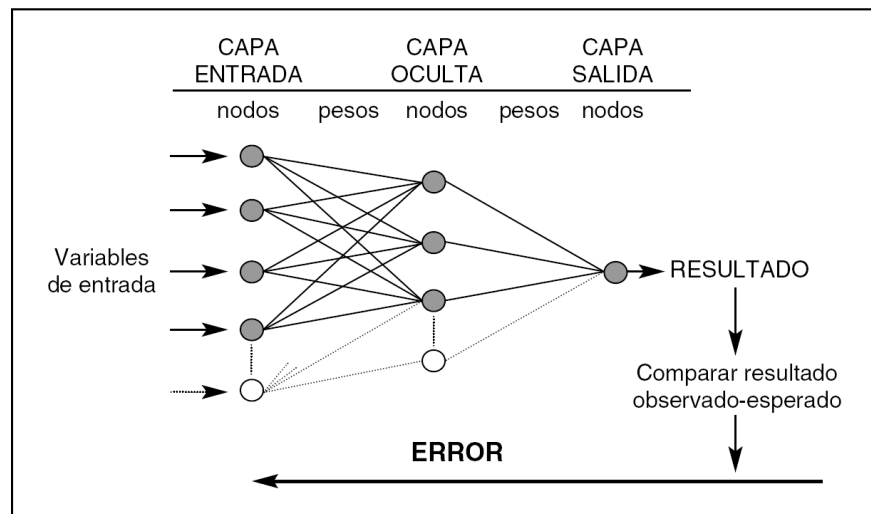


una maquina diseñada originalmente para modelar la forma en que el sistema nervioso de un ser vivo realiza una determinada tarea. Para lograr este objetivo, una red neuronal está formada por un conjunto de unidades de procesamiento interconectadas llamadas neuronas.

### Red neuronal artificial

De acuerdo a Calderón (2012). Las redes neuronales artificiales según Teuvo Kohonen son redes interconectadas masivamente en paralelo de elementos simples y con organización jerárquica, las cuales intentan interactuar con los objetos del mundo real del mismo modo que lo hace el sistema nervioso biológico.

### Representación de una red neuronal con 3 capas



**Figura 2: Estructura de red neuronal multicapa**

Donde:

- o Capa de Entrada: Se encuentran las neuronas que van a tener la función de receptoras de estímulos (información), provenientes del medio exterior, estas entradas pueden ser de dos tipos, binarias o reales.
- o Capa Oculta : Estas neuronas artificiales pueden ser parte de la red neuronal como también se pueden obviar dependiendo de la topología seleccionada, se encargan de hacer el procesamiento de información y cuyas salidas serán enviadas a una siguiente capa que puede ser la capa de salida o también a otra capa oculta.
- o Capa de Salida: Las neuronas que se encuentran en esta capa serán las encargadas de dar el resultado de todo el procesamiento de la red, es

decir cuál ha sido su comportamiento final frente a los estímulos iniciales recibidos.

### Elementos básicos

De acuerdo con Eybi Gil y Rodríguez Edith (2010). Una RNA es muy parecida a lo que en matemática discreta se estudia como “grafos”. En el caso más simple, cada neurona tiene una serie de variables respecto a si misma. En todo modelo artificial de neurona se tienen cuatro elementos básicos:

- Un sumador, que se encarga de sumar todas las entradas multiplicadas por las respectivas sinapsis.
- Un conjunto de conexiones, pesos o sinapsis que determinan el comportamiento de la neurona. Estas conexiones pueden ser excitadoras (presentan un signo positivo), o inhibitoras (conexiones negativas).
- Una función de activación, lineal o no lineal para limitar la amplitud de la salida de la neurona.
- Un umbral exterior, que determina el umbral por encima del cual la neurona se activa.

Esquemáticamente sería de la siguiente forma:

### Representación de una neurona artificial




Figura 2.6

## Función de Activación

De acuerdo con Damián Matich (2012). Una neurona biológica puede estar activa (excitada) o inactiva (no excitada); es decir, que tiene un “estado de activación”. Las neuronas artificiales también tienen diferentes estados de activación; algunas de ellas solamente dos, al igual que las biológicas, pero otras pueden tomar cualquier valor dentro de un conjunto determinado.

De acuerdo con Damián Matich (2012). La función de activación calcula el estado de actividad de una neurona; transformando la entrada global (menos el umbral,  $\theta_i$ ) en un valor (estado) de activación, cuyo rango normalmente va de (0 a 1) o de (-1 a 1). Esto es así, porque una neurona puede estar totalmente inactiva (0 o -1) o activa (1).

De acuerdo con Sobrevilla (2010). Las funciones más utilizadas son:

**Función Escalón:** Se utiliza únicamente cuando las salidas son binarias, matemáticamente se expresa como:

### Función Escalón

$$y_k = \begin{cases} 1, & n_k \geq 0; \\ -1, & n_k < 0. \end{cases}$$




Figura 2.7 (Sobrevilla)

**Función Lineal:** Se usa en diversos tipos de redes, con frecuencia en la capa de salida. El rango de salida puede contener cualquier número real, matemáticamente se expresa como:

## Función Lineal




Figura2.8 (Sobrevilla)

**Función Sigmoidal:** Con esta función, para la mayoría de los valores de entrada, el valor dado es cercano a uno de los valores asintóticos. Esto hace que, en la mayoría de los casos, el valor de salida esté comprendido en la zona alta o baja del sigmoide.

## Función Sigmoidal

$$y_k = \frac{1}{1 + e^{-x_k}}$$




Figura 2.9 (Gil)

**Función Tangente Hiperbólica:** Es semejante a la sigmoidal, pero su rango de salida está entre -1 y 1, matemáticamente se expresa como:

## Función Tangente Hiperbólica

$$y_k = \tanh(n_k)$$




Figura 2.9 (Sobrevilla)

### Algoritmo Backpropagation

Francisco Ortega-Zamorano, José M. Jerez, Daniel Urda Muñoz, Rafael M. Luque-Baena, and Leonardo Franco (2016). El algoritmo BP es un método de aprendizaje supervisado para el entrenamiento de redes neuronales artificiales multicapa, e incluso si el algoritmo es muy conocido, resumimos en esta sección las principales ecuaciones en relación con la implementación del algoritmo BP, ya que son importantes para entender su funcionamiento.

Consideremos una arquitectura de red neural que comprende varias capas ocultas. Si consideramos las neuronas pertenecientes a una capa oculta o de salida, la activación de estas unidades, denotada por  $Y_i$ , puede escribirse como:

$$y_i = g \left( \sum_{j=1}^L w_{ij} \cdot s_j \right) = g(h) \quad (1)$$

Donde  $W_{ij}$  son los pesos sinápticos entre la neurona  $i$  en la capa actual y las neuronas de la capa anterior con activación  $s_j$ . En (1), hemos introducido  $h$  como el potencial sináptico de una neurona.  $g$  es una función de activación sigmoide dada por.

$$g(x) = \frac{1}{1 - e^{-\beta x}}. \quad (2)$$

El objetivo del algoritmo de aprendizaje supervisado por BP es minimizar la diferencia entre salidas (objetivos) dadas para un conjunto de datos de entrada y la salida de la red. Este error depende de los valores de los pesos sinápticos, por lo que deben ajustarse para minimizar el error. La función de error calculada para todas las neuronas de salida se puede definir como.

$$E = \frac{1}{2} \sum_{k=1}^P \sum_{i=1}^M (z_i(k) - y_i(k))^2 \quad (3)$$

Donde la primera suma está en los P patrones del conjunto de datos y la segunda suma está en las neuronas de salida M (número de neuronas de la capa oculta).  $Z_i(k)$  es el valor objetivo para la neurona de salida  $i$  para el patrón  $K$  y  $Y_i(k)$  es la salida de respuesta correspondiente de la red. Usando el método de descenso de gradiente, la BP intenta minimizar este error en un proceso iterativo actualizando los pesos sinápticos sobre la presentación de un patrón dado. Los pesos sinápticos entre dos últimas capas de neuronas se actualizan como:

$$\Delta w_{ij}(k) = -\eta \frac{\partial E}{\partial w_{ij}(k)} = \eta [z_i(k) - y_i(k)] g'_i(h_i) s_j(k) \quad (4)$$

Donde  $\eta$  es la tasa de aprendizaje que se tiene que establecer de antemano (un parámetro del algoritmo),  $g'$  es la derivada de la función sigmoide, y  $h$  es el potencial sináptico definido previamente, mientras que el resto de los pesos se modifican según similar Ecuaciones por la introducción de un conjunto de valores llamados deltas ( $\delta$ ), que propagan el error forman la última capa en las internas.

El conjunto de entrenamiento se utilizará para ajustar los pesos sinápticos de acuerdo con (4), mientras que el conjunto de validación se utiliza para controlar los efectos de sobreensado, almacenando en memoria los valores de los pesos sinápticos que hasta ahora han conducido al error de validación más bajo. Cuando el procedimiento de entrenamiento termina, el algoritmo devuelve el conjunto de pesos almacenado. El conjunto de pruebas se utiliza para estimar el rendimiento del algoritmo en patrones de datos no vistos.

### **1.3 Motivación de la propuesta**

El motivo del diseño de la arquitectura de perceptron multicapa para generar un modelo predictivo del rendimiento académico universitario se basa en que no existen investigaciones que ataquen este problema en el contexto de nuestro caso de estudio.

Hashmia Hamsa, Simi Indiradevi, Jubilant J. Kizhakkethottam (2016). Donde se usa grandes cantidades de información para realizar la predicción. Rui Wang, Gabriella Harari, Peilin Hao, Xia Zhou, y Andrew T. Campbell (2015). Indica como con la información de los Smartphone se puede realizar una predicción del rendimiento académico, con información de los sensores. Se concluye que se necesita una arquitectura que genere predicción en otro tipo contexto, en donde se usa menor información y de una manera más ágil, es decir de una manera inmediata, en donde la información que el estudiante universitario académico ingrese será según su forma de organizarse y se podrá generar una predicción. Santhosh Nagulan, Jegadheeswaran Selvaraj, Amarkarthik Arunachalam y Kaushik Sivanandam (201). Validaron el uso de una red neuronal artificial supervisada para generar una predicción.

### **1.4 Objetivos**

#### **1.4.1 Objetivo general**

Diseñar una arquitectura de redes neuronales utilizando perceptron multicapa con backpropagation para generar un modelo predictivo del rendimiento académico de los estudiantes universitarios.

#### **1.4.2 Objetivos específicos**

- Especificar las variables definidas del problema en el contexto del estudio.
- Diseñar la Arquitectura perceptron multicapa con backpropagation.
- Diseñar una herramienta organizativa que gestione la información de los estudiantes según las variables definidas.
- Validar el rendimiento del modelo predictivo con una técnica de evaluación.

# CAPÍTULO II: ESTADO DEL ARTE

## 2.1 Prefacio

La presente investigación se realizó con el fin de proponer una arquitectura en perceptrón multicapa con back propagation para predecir el rendimiento académico universitario, se presenta como caso para la validación del modelo el contexto universitario peruano, específicamente en la Universidad Nacional Mayor de San Marcos. Se inició la investigación con el estudio de la problemática que existe en el rendimiento de los estudiantes universitarios en la actualidad, y así determinando que existe una problemática, seguidamente se realizó una investigación de modelos predictivos del rendimiento académico, y su aplicación en diversos contextos y condiciones, revisando los resultados obtenidos. Con esta información obtenida se pudo determinar la falta de arquitecturas o modelos de minería de datos para predecir el rendimiento académico universitario de una manera que el propio estudiante puede recibir los resultados y tomar sus propias decisiones.

Los artículos de investigación estudiados están directamente ligados a la predicción de rendimiento académico, en donde explican las distintas metodologías para la creación de un modelo predictivo, las técnicas aplicadas para la calificación de información, la obtención del resultado predictivo, la mejora de la calidad de información, la comparación entre diferentes algoritmos en base a los resultados. El primer tópico, Algoritmos clasificadores para generar modelos de predicción del rendimiento académico, está conformado por 5 artículos, que describen las técnicas para obtener los resultados de la predicción.

Hashmia Hamsa, Simi Indiradevi y Jubilant J. (2016). Trata las técnicas de clasificación que se hacen a registros académicos para generar un modelo, las técnicas fueron Árbol de Decisiones (DT) y Algoritmo Genético Difuso (FGA). S. Merchán, Miembro de IEEE y J. Duarte. (2016). Trata las técnicas para crear el árbol que representa la clasificación utilizando J48, PART Y RIDOR. Krina Parmar, Dineshkumar Vaghela y Priyanka Sharma. (2015), se trata de la técnica que se utilizó en su validación, la técnica es un árbol de decisión aleatorio generando las reglas de la predicción. Mvurya Mgala, Audrey Mbogho. (2015). Trata de las técnicas que se utilizó para generar el modelo, en este caso se trata de clasificadores los cuales fueron 8, Regresión Logística, Perceptron multicapas, Algoritmo SMO, Clasificadores de red Bayesiana, Clasificador naive de Bayes, Aprendizaje perezoso, Clasificador de bosque al azar, y el algoritmo J48. Camilo E. López G., Elizabeth León Guzmán and Fabio A. González. (2015). se trata las técnicas de clasificación utilizadas para generar un modelo predictivo, se utilizó Árbol de decisiones y un Clasificador Bayesiano.

Por otro lado, el segundo tópico, Metodologías para definir una arquitectura de predicción de rendimiento académico, consta de metodologías propuestas para la creación de un modelo



predictivo de rendimiento académico, integrado por 5 artículos. Rui Wang, Gabriella Harari, Peilin Hao, Xia Zhou, y Andrew T. Campbell (2015), trata de la manera en cómo se da el proceso de creación de un modelo predicción, partiendo por el Conjunto de Datos (StudentLife), captura de cambios conductual (datos), relación entre cambios de información y el rendimiento con una técnica definida, finalmente se obtiene el modelo en este artículo con regresión lineal. Abelardo Pardo, Negin Mirriahi y Roberto Martínez (2015), trata de la manera en cómo se da el proceso de creación de un modelo predicción, iniciando de las fuentes de información en este caso derivadas de la interacción del estudiante con una aplicación, luego se mide el rendimiento de los modelos utilizando técnicas (Mean Absolute Error, error cuadrático medio), obtener un modelo de validación de con la estrategia Crossvalidation, finalmente se obtuvo los modelos de predicción con la técnica de partición recursiva (generando un árbol). Abelardo Pardo, Feifei Han, and Robert A. Ellis (2017), trata de la manera en cómo se da el proceso de creación de un modelo predicción, implica la información (participantes), el contexto del caso de estudio, los instrumentos utilizados (variables aprendizaje autorregulado, información de aplicaciones utilizadas por estudiante, marca finales del curso para la medida rendimiento), finalmente la técnica Análisis de factores Exploratorios (EFA) para analizar los datos (variables y los resultados). Camilo E. López G., Elizabeth León Guzmán and Fabio A. González. (2015), Busca contribuir con un marco genérico para predecir los riesgos de despeño, donde se propone un conjunto de sub-tareas para el análisis y experimentación: predecir el nivel de subprueba de cada estudiante, predecir el nivel de tema específico de cada estudiante. Creando una metodología para generar el modelo de predicción: 1) se procesa los datos o información, que tiene subprocesos, los cuales son la combinación de registros fusionados, 2) preparar los datos de los registros fusionados para la construcción de los modelos. 3) manejo de la falta de datos, 4) procesamiento adicional de los datos J.C. Cortés, J. M. Colmenar, J. I. Hidalgo, A. Sánchez-Sánchez, F.J. Santonja, R.J. Villanueva (2016), proponen un modelo de red aleatoria para realizar la creación de modelo predictivo, aplicando su metodología propuesta: Los datos disponibles, los supuestos (consisten en identificar cada estado estudiantil mediante la codificación de todas las etiquetas posibles de los estudiantes), Descripción de la red (se define el modelo de red tomando en cuenta los supuestos) y la evolución de la red. Debido a la cantidad de parámetros que se tienen se realiza una búsqueda óptimos parámetros para la función objetivo que resuelve el problema, el autor uso el algoritmo DE (Evolución Diferencial), para reducir la función objetivo y mejor el intervalo de confianza de la predicción.

TIPOLOGIA	TITULO DEL ARTÍCULO	AUTORES
-----------	---------------------	---------

<b>Algoritmos clasificadores para generar modelos de predicción del rendimiento académico</b>	Modelo de predicción de rendimiento académico usando árbol de decisión y algoritmo genético difuso	HASHMIA HAMSA, SIMI INDIRADEVI, JUBILANT J. KIZHAKKETHOTTAM
	Análisis de las técnicas de minería de datos para la construcción de un modelo predictivo para el desempeño académico	S. M. MERCHÁN, MEMBER, IEEE AND J. A. DUARTE
	Predicción del desempeño de estudiantes usando minería de datos distribuidos	KRINA PARMAR PROF. DINESHKUMAR VAGHELA DR PRIYANKA SHARMA
	Modelo de predicción de nivel de intervención dirigida por datos para el rendimiento académico	RUI WANG, GABRIELLA HARARI, PEILIN HAO, XIA ZHOU, AND ANDREW T. CAMPBELL
	Un modelo para predecir el desempeño académico bajo en una inscripción específica utilizando la minería de datos	CAMILO E. LÓPEZ G., ELIZABETH LEÓN GUZMÁN AND FABIO A. GONZÁLEZ
<b>Metodologías para definir una arquitectura de predicción de rendimiento académico</b>	Como los Smartphones pueden predecir el rendimiento académico	RUI WANG, GABRIELLA HARARI, PEILIN HAO, XIA ZHOU, AND ANDREW T. CAMPBELL
	Generación de modelos predictivos accionables de desempeño académico	ABELARDO PARDO, NEGIN MIRRIAH, ROBERTO MARTINEZ-MALDONADO
	Combinación de indicadores de aprendizaje auto-regulados de estudiantes universitarios y participación en eventos de aprendizaje en línea para predecir el rendimiento académico	ABELARDO PARDO, FEIFEI HAN, AND ROBERT A. ELLIS
	Predicción temprana de riesgos en el desempeño académico para estudiantes	S. IKBAL, A. TAMHANE, B. SENGUPTA, M. CHETLUR, S. GHOSH, J. APPLETON
	Modelar y predecir los resultados académicos del bachillerato español en los próximos años utilizando un modelo de red aleatorio	J.C. CORTÉS, J. M. COLMENAR, J. I. HIDALGO, A. SÁNCHEZ-SÁNCHEZ, F.J. SANTONJA, R.J. VILLANUEVA

TABLA 1: RESUMEN DE TIPOLOGIAS

## 2.2 Algoritmos clasificadores para generar modelos de predicción del rendimiento académico

Hashmia Hamsa, Simi Indiradevi y Jubilant J. (2016), proponen un modelo de minería de datos para generar la predicción de rendimiento académico. El autor realiza una tarea de clasificación (minería de datos) con los registros académicos que dispone, en este proceso lo que se hace es asignar una etiqueta o clase predefinida basado en un conjunto de datos predefinidos, utilizando como técnica de FGA (Algoritmos genéticos difusos) y DT (Árbol de decisiones). Para resolver el problema se implementa como se mencionó anteriormente 2 técnicas paralelamente y así poder comparar los resultados obtenidos estas son: DT Árbol de decisiones, para la decisión del árbol se utilizó el algoritmo C4.5, mientras que para el FGA

posee dos elementos computacionales que trabajan juntos: El algoritmo genético (GA) y Fuzzy Fitness Finder (FFF). En primer lugar, la investigación contribuye en generar un modelo de predicción a partir de un modelo de minería de datos, reduciendo así los riesgos de obtener un rendimiento académico bajo. En segundo lugar, se aporta la evidencia de los resultados obtenidos: en los resultados obtenidos en DT que sigue decisiones estrictas predefinidas, determina que los estudiantes en la barrera del éxito serán identificados como en riesgo, así en punto de vista del profesor, los estudiantes de nivel medio también se encontrarán bajo el cuidado de expertos. Mientras que en FGA, se determina que los estudiantes que tienen una puntuación baja en algunos atributos tienen la oportunidad de estar a salvo debido a la alta puntuación obtenida de otros atributos que hacen que los estudiantes se sientan cómodos. Desde una perspectiva experimental, el resultado del Árbol de Decisiones obtuvo más estudiantes en la Clase en riesgo, mientras que los resultados en el FGA se obtuvo más estudiantes seguros (sin riesgo) aun así los docentes le prestaran atención indirectamente, así creando un ambiente amistoso entre docentes y estudiantes. Generando así estudiantes expertos, de la misma manera un reclutamiento por empresas de renombre y prestigio para la escuela.

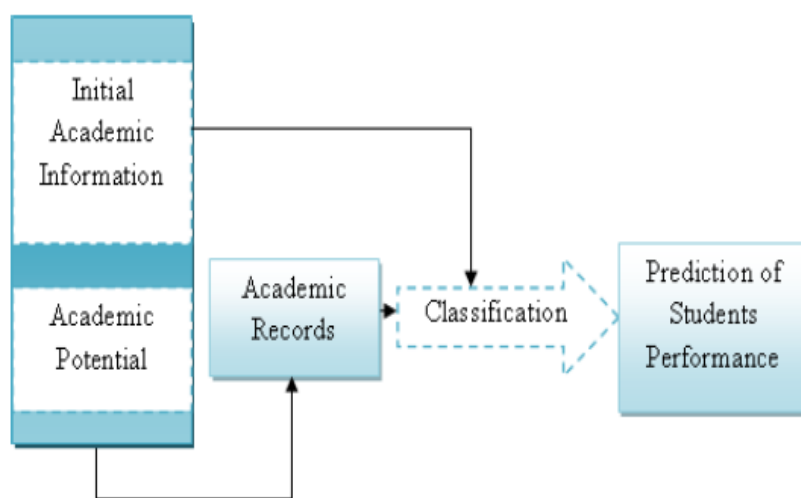


Fig. 1 Modelo propuesto de Minería de datos

S. Merchán y J. Duarte. (2016), proponen un modelo de minería de datos iterativo para la predicción de rendimiento académico para luchar contra la deserción estudiantil. El autor realiza una tarea de extracción y preparación de datos que consiste en lo siguiente: extraer información de la base de datos (información académica y demográfica) y su posterior limpieza de datos (consistencia) y generando 2 grupo uno para ser minado y el otro para evaluar la tasa de error del método clasificador, generar la estructura de los datos (estructura de instancia), finalmente se define la variable de salida del modelo será el desempeño

académico. Luego de preparar los datos el autor realiza el proceso de generar el modelo, utilizando una herramienta, WEKA es la herramienta a utilizar, utilizando un archivo ARFF con toda la información obtenida, para poder ser procesada: pre procesamiento de datos, minera de datos e interpretación de resultados. En primer lugar, la investigación contribuye en generar un modelo de predicción a partir de un modelo de minería de datos iterativo, reduciendo así los riesgos de la deserción estudiantil. En segundo lugar, se aporta la evidencia de los resultados obtenido producto de 4 iteraciones ejecutas. En tercer lugar, se aporta los resultados obtenidos, en relación con la cantidad de reglas obtenidas y la precisión alcanzada en las clasificaciones. En cuarto lugar, se aporta los resultados obtenido, la Tabla 5 muestra los resultados obtenidos a través de cada iteración, en relación con la precisión de la clasificación para cada una de las variables de salida definidas para el desempeño académico. Desde una perspectiva experimental, los resultados de las 3 técnicas tuvieron serios problemas en sus primeras iteraciones, por lo que se hicieron ajustes a las instancias, se removió atributos redundantes como causas del mal desempeño, generando aumento de reglas considerablemente, aun así, la precisión seguía siendo baja por lo que se interpretó que las reglan no se desempeñaban bien con el conjunto de entrenamiento, causados por instancias que no proveen datos útiles al algoritmo. En la cuarta y final iteración se aplicó el filtro de preprocesamiento para remover instancias no clasificadas, utilizando el algoritmo J48, por su tener el mejor desempeño promedio. Finalmente, el conjunto de datos de entrenamiento se redujo en un 60% pero se generó conocimientos más valiosos y significativos, manteniendo niveles de precisiones favorables y tolerables.

	J48	PART	RIDOR
Iteración #1	R: 81% P:62.7% S:83.30%	R: 64.7% P:57.1% S:78.8%	R: 72.2% P:71.8% S:69.6%
Iteración #2	R: 27.8% P:42.3% S:0%	R: 16.7% P:42.6% S:0%	R: 47.9% P:40.2% S:22.7%
Iteración #3	R: 43.2% P:42.7% S:18.2%	R: 34.8% P:40.3% S:25.4%	R: 44.5% P:37.5% S:22.1%
Iteración #4	R: 86.8% P:85.3% S:76.9%	R: 85.4% P:83.3% S:66.7%	R: 64.9% P:55.3% S:25%

TABLA 2. Tasas de precisión obtenidas por cada algoritmo de acuerdo con la variable de salida (R: Riesgo, P: Desempeño promedio, S: Desempeño sobresaliente)

Krina Parmar, Dineshkumar Vaghela y Priyanka Sharma. (2015), Proponen un modelo de predicción de rendimiento académico para mejorar el rendimiento de los estudiantes. El autor

primero propone tener un modelo local, para en base a este poder generar las reglas para un modelo global, para que los conocimientos obtenidos sean útiles a nivel global. El modelo se genera en una arquitectura de minería de datos distribuida con sus orígenes de datos generando así varios modelos locales, para luego complementar estos modelos y finalmente tener el modelo final que funcione de manera global. En primer lugar, el modelo genera reglas, por cada nodo y los nodos centrales generando así los modelos considerados locales. Todos los experimentos se realizan en java usando Netbeans 7.0 con el uso del entorno de ejecución WEKA. El algoritmo de árbol de decisión aleatorio se aplica a los conjuntos de datos de "PARUL INSTITUTE STUDENT" de cada uno de los cuales tienen 1000 registros. Por medio de estas reglas de clasificación se generan en cada nodo a partir de conjuntos de datos de entrenamiento. Estas reglas se combinan utilizando el método de clasificación específica para crear el modelo global en el lado central. Ahora estas reglas se aplican en conjuntos de datos de prueba en el lado central para predecir el rendimiento del estudiante. La distribución del entrenamiento y la tarea de la prueba de la clasificación en cada nodo y el nodo central respectivamente mejora la clasificación y la tarea de la predicción en datos grandes y distribuidos. Prever el funcionamiento del estudiante es útil crear fuerza de trabajo estudiantil eficiente y buena de calidad, Mejorar su desempeño seguramente será beneficioso para sus resultados individuales y también para el perfil de la institución académica. En la Figura 1 observamos la arquitectura propuesta.




Figura 1. Framework distribuido

Mvurya Mgala, Audrey Mbogho (2015), Proponen un modelo predictivo que permita predecir con mucha anterioridad cómo será el rendimiento del alumno. El autor primero

propone una metodología: recopilación de datos, preparación de datos, partición de datos, modelos de capacitación, modelos de evaluación y reducción de característica: La reducción de características se lleva a cabo para determinar un subconjunto de características óptimo utilizando correlación. Un segundo conjunto de experimentos se lleva a cabo para determinar la posibilidad de utilizar un conjunto de datos óptimo que podría ahorrar en recursos informáticos y el tiempo. La predicción del nivel de intervención del estudiante está en una tarea de clasificación binaria con el objetivo de categorizar a los estudiantes en dos grupos: 1) intervención alta e 2) intervención baja. Las características del conjunto de datos se introducen en el algoritmo de selección de características con sus ganancias de información correspondientes. Cuanto mayor sea el valor de la ganancia de información, más relevante será la función para el entrenamiento. Luego del segundo experimento se realiza la creación de los modelos, donde WEKA es la herramienta que utilizar. Seguidamente se realiza la implementación, donde se utilizó ocho clasificadores: La regresión logística, Perceptron de múltiples capas, El algoritmo de optimización mínima secuencial (SMO), Clasificadores de red bayesiana, El clasificador naïve de Bayes, Los aprendices perezosos (Elegimos el tipo de aprendizaje ponderado localmente (LWL)), Clasificador de bosque al azar, El algoritmo J48. En primer lugar, la investigación contribuye en generar un modelo de predicción a partir de 2426 registros de estudiantes, que viene a ser el conjunto de datos a clasificar. Debido a la sensibilidad por ser un modelo con salidas tipo binaria se aplica tres medidas diferentes: el porcentaje de precisión, la curva de características de funcionamiento del receptor (ROC) y la medida F. T. Fawcett. Gráficos Roc (2004). La curva ROC es una técnica gráfica útil para organizar, visualizar y seleccionar los clasificadores en función de su rendimiento. Desde una perspectiva experimental, muestra la comparación de los tres valores métricos obtenidos utilizando ocho clasificadores para las predicciones de intervención. Utilizamos varias implementaciones clasificadoras en WEKA.

	Accuracy	ROC area	F-measure
Lazy (LWL)	83.4707	0.828	0.834
Multi. perceptron	79.761	0.828	0.794
Logistic	83.883	0.878	0.836
Tree (J48)	82.6051	0.779	0.819
Random Forest	81.3273	0.841	0.811
Bayes Net	83.2646	0.870	0.830
Naive Bayes	73.9901	0.835	0.748
SMO	83.388	0.800	0.832

Tabla 3: Comparación del rendimiento de los clasificadores

Camilo E. López G., Elizabeth León Guzmán and Fabio A. González. (2015), proponen un modelo de minería de datos que permita identificara los estudiantes que están en riesgo de abandonar lo antes posible, así como entender que factores que factores tienen una mayor

influencia en esto. El autor primero propone una secuencia de pasos para la creación del modelo predictivo, Los Data Sets y Preprocesamiento. Los Data Sets vienen a ser los datos que servirán para entrenar y validar el modelo. Para construir los modelos se utilizan dos técnicas ampliamente utilizadas: árboles de decisión, en este trabajo, se utiliza el algoritmo C4.5 y un clasificador Bayesiano. Los datos de tipo estudiantil son: socioeconómico, demográfico y la información académica inicial (todos reunidos del proceso de admisión); y los registros académicos de los períodos académicos anteriores. En primer lugar, la investigación contribuye en generar un modelo de predicción a compuesto por registros de estudiantes matriculados entre 2007-II a 2012-I, que viene a ser los Data Sets, se dividió en diez grupos igualmente distribuidos. El modelo aprendió de nueve de ellos, correspondiente al conjunto de formación, y luego se evaluó en el décimo grupo, correspondiente a un conjunto de validación. El proceso se repitió diez veces para que cada grupo se utilizara para aprender y probar. Este conjunto de datos utiliza los datos de los primeros diez períodos académicos. En segundo lugar, se aporta la evidencia de los resultados obtenidos, donde en los primeros experimentos fueron previstos para predecir la pérdida de estatus académico en cualquiera de los primeros cuatro períodos académicos usando los datos iniciales, pero los resultados no fueron satisfactorios; la precisión balanceada oscilaba entre 51 y 52% en el árbol de decisión y entre el 54-57% en Bayes ingenuo. El siguiente conjunto de experimentos tenía como objetivo predecir no sólo el caso de pérdida de estatus académico, sino también el semestre en el que se produce. Primero, sólo se utilizaron los datos iniciales para predecir el bloqueo de la historia académica en la segunda, tercera y cuarta matriculación. Los algoritmos fueron probados con el período académico 2012-II. Los resultados tienen un comportamiento similar al utilizar el árbol de decisión con un aumento en el rendimiento en la predicción en la primera inscripción y una disminución posterior. Bayes ingenuo, por otro lado, mostró un comportamiento irregular en las predicciones en la matrícula 3 y un cambio en el rendimiento de las diferentes matrices de costos utilizadas. El siguiente paso fue incluir los registros académicos en los datos. Como se describió anteriormente, los datos académicos utilizados son los grados y porcentaje de créditos matriculados y aprobados en el período académico anterior. Bayes Ingenuo tuvo los mejores resultados, superando el 75% en precisión equilibrada, hasta el 85% en la cuarta inscripción en el test set. El árbol de la decisión no mostraba mucho de una mejora, a excepción de la segunda inscripción. También es importante notar que las calificaciones se vuelven más relevantes a medida que avanza el tiempo, cuando se intenta predecir la pérdida de estatus académico en una inscripción posterior; en este escenario, estas características obtienen aún más importancia que los datos socioeconómicos y demográficos. En cuanto a la cuestión de qué datos se deben utilizar para entrenar el modelo, los experimentos mostraron un mejor rendimiento cuando los modelos fueron aprendidos con los datos de ambos programas en lugar de aprender modelos independientes, especialmente cuando se utilizan árboles de decisión

En conclusión, tanto el trabajo de Hamsa et al. (2016) como el de Merchán et al. (2016), utilizan algoritmos clasificadores para poder obtener un modelo predictivo, sin embargo este último utilizó un proceso iterativo en sus minería de datos para mejorar los resultados, concluyendo que ajustar las instancias, remover atributos que no aportan es de gran importancia para obtener mejores resultados en la predicciones mientras que Parmar et al. (2015), proponen un modelo de minería de datos de tipo distribuida, lo que permite generar un modelo global, lo que mejora para predecir entre grandes datos y distribuidos. Mgala et al. (2015), aplican la reducción de características utilizando método de correlación lo que mejora la predicción del rendimiento académico, y a diferencia de los otros autores al tener sus outputs de tipo binario el autor propone aplicar tres medidas para medir el rendimiento de sus clasificadores. Por otro lado, López et al. (2015), demuestra en a través del tiempo los clasificadores bayesianos presentan mejores resultados que un árbol de decisiones al final del entrenamiento.

### **2.3 Metodologías para definir una arquitectura de predicción de rendimiento académico**

Rui Wang, Gabriella Harari, Peilin Hao, Xia Zhou, y Andrew T. Campbell (2015), Proponen la manera de como poder deducir el comportamiento de los estudiantes, para que con esta información se puede predecir el rendimiento académico según varios factores, ya que se desea entender el por la variación del GPA acumulativo de un estudiante en relación con otro. El autor primero propone la construcción de un modelo predictivo basado en autoinformes (conocimiento de uno mismo) y las características de comportamiento detectado obtenido de sus teléfonos inteligentes en donde un objetivo de esta investigación es utilizar medidas discretas y longitudinales de los comportamientos de estilo de vida de los estudiantes para predecir el rendimiento. La metodología creada consiste en: el Conjunto de Datos (StudentLife), captura de cambios conductual, Análisis de Correlación con la técnica de Pearson, finalmente se obtiene el modelo predictivo con regresión lineal con regularización lazo. En primer lugar, es importante entender mejor la relación entre los comportamientos estudiantiles, las emociones, la salud mental y la personalidad, y los resultados académicos, realizamos el análisis de correlación de Pearson. Identificamos una serie de correlaciones fuertes y significativas. GPA del Término de Primavera. La media del GPA del término de primavera es 3.3306 y la desviación estándar es 0.7983. La asimetría, sin embargo, es -1.7725, lo que significa que la mayoría de los estudiantes reciben altos GPAs para el término y sólo una pequeña porción de los estudiantes obtienen bajos GPAs. En términos de otros comportamientos deducidos de la detección automática, encontramos una disminución de la actividad física a lo largo del término, particularmente después de que el punto intermedio se correlaciona negativamente con el término del GPA, lo que significa que los estudiantes que experimentan una disminución en sus niveles de actividad física son más propensos a tener mayores GPAs. Por último, encontramos que la escala de estrés percibida se correlaciona



negativamente con el GPA del término de primavera, lo que significa que los estudiantes que están menos estresados son más propensos a tener mayores GPAs. Se aplicó la validación cruzada “leave one subject out” (dejar uno afuera) para determinar los parámetros para Lasso y los pesos para cada característica. Para que la regularización del peso funcione correctamente, cada característica se escala dentro del rango [0; 1]. Desde una perspectiva experimental, los estudiantes que tienen mejores GPAs son más conscientes, estudian más, experimentan estados de ánimo positivos (por ejemplo, alegría, interés, estado de alerta) a lo largo del término, pero registran una caída en el afecto positivo después del punto intermedio, experimentan niveles más bajos de estrés a medida que el término progresa. Menos social en términos de conversaciones durante el período nocturno entre las 6 y las 12 pm, y experimentar un cambio posterior (es decir, un punto de interrupción del comportamiento) en su patrón de duración de la conversación. En el caso del GPA del término de la primavera, Lasso no selecciona características para la predicción. En su lugar, elige utilizar la intercepción sola para predecir los resultados del GPA del término de primavera; Es decir, elige un solo valor 3.40 para predecir el promedio en primavera para todos los estudiantes con MAE = 0.53 y el error absoluto medio de 0.38. Creemos que esto es debido a la asimetría del GPA al término de la primavera.

Abelardo Pardo, Negin Mirriahi y Roberto Martínez (2015), proponen un modelo basado en datos que utiliza métodos analíticos para predecir el rendimiento académico buscando mejorar la calidad de la experiencia del estudiante. Para el autor el desafío radica en la brecha de conocimiento entre: 1) cómo los datos son capturados, procesados y utilizados para derivar modelos de conducta estudiantil, 2) la posterior interpretación y la decisión de desplegar acciones pedagógicas e intervenciones de instructores, Con el fin de apoyar el cambio pedagógico y la interpretación de la ayuda, este trabajo propone un modelo que puede permitir a los instructores identificar fácilmente subpoblaciones de estudiantes para proporcionar acciones específicas de apoyo. En primer lugar, el estudio utilizó varias fuentes de datos derivadas de la interacción de los estudiantes con los componentes del curso, a saber, cuatro tipos de actividades. El primer tipo (VID) consistía en una página HTML interactiva con un videoclip que introducía nuevos conceptos de curso. Se grabaron todos los eventos de reproducción y pausa en los videoclips. El segundo tipo de actividades (VEQ) se incluyeron inmediatamente al lado del video clip y consistió en una evaluación formativa en forma de preguntas de opción múltiple relacionadas con los conceptos cubiertos en el clip de video adjunto. Las variables utilizadas como predictores para construir los modelos se derivaron de la interacción de los estudiantes con los diversos recursos de diseño de aprendizaje disponibles en una plataforma en línea. Dado que el curso tiene tareas y evaluaciones debidas cada semana, las variables utilizadas para el análisis son los conteos semanales para los eventos de actividad en once semanas de curso básico. Se extrajo de los registros del servidor. Los datos se recogieron en la oferta de 2014 de un gran curso de ingeniería de primer año (n

= 272). El programa semanal incluyó una conferencia de 2 horas, un tutorial de 2 horas y una sesión de laboratorio de 3 horas. Los datos fueron extraídos de los registros del servidor y completamente anónimos. En segundo lugar, el estudio tuvo como objetivo mostrar la viabilidad de obtener un modelo predictivo del desempeño de los estudiantes en el examen de medio y final utilizando los datos sobre su interacción con las actividades en línea. Esencialmente, el estudio exploró la idoneidad de las técnicas predictivas que pueden manejar indicadores numéricos y proporcionar una interpretación simple de los resultados. El rendimiento del modelo se midió utilizando el Mean Absolute Error (MAE) definido como la media de las diferencias entre las puntuaciones predichas y reales, y la raíz del error cuadrático medio (RMSE) definida como la raíz cuadrada de la media de la media Cuadrado entre las puntuaciones predichas y reales (MSE). El modelo de validación se realizó después de dejar una estrategia de Crossvalidation. Para cada una de las muestras se calculó un modelo dejando una muestra y se obtuvo su error en la estimación (en la muestra de la izquierda). Los errores se combinaron para calcular MAE y RMSE. Para construir los modelos de uso la técnica de partición recursiva. Para cada semana del curso, se extrajo un conjunto de variables y se utilizó para calcular los modelos predictivos. Por ejemplo, el modelo de la semana 3 se calculó con el conjunto de variables que refleja el número de eventos registrados durante esa semana (ignorando el resto). Estos modelos (once de ellos) se dividieron en dos categorías: las que predijeron el desempeño de los estudiantes en el examen de mitad de período (para las semanas 2 a 5) y las que predijeron el desempeño en el examen final (semanas 7 a 13). Los resultados de los exámenes de mitad de período y final son variables numéricas con valores en el rango [0-20] y [0-40], respectivamente. Desde una perspectiva experimental, se observa las estadísticas descriptivas (media y desviación estándar) para cada una de las variables durante las once semanas básicas del curso se muestran en la Tabla 1. La media y la desviación estándar de las puntuaciones intermedias y finales fueron 13,3 (4,1) y 19,1 (8,8), respectivamente. Los modelos predictivos fueron calculados para todas las once semanas del semestre usando partición recursiva. Para cada modelo, se produjo una colección de reglas y una estructura de árbol. Las reglas se establecieron como condiciones sobre las variables de entrada (conteos de eventos). Cada nodo del árbol fue etiquetado con una condición y dos bordes salientes.

	MSE	RMSE	MAE
W7	29.182	5.402	4.4
W8	32.358	5.688	4.726
W9	28.905	5.376	4.481
W10	32.101	5.666	4.665
W11	30.436	5.517	4.482
W12	25.476	5.047	4.097
W13	32.037	5.66	4.503

Tabla 4: Rendimiento al estimar el puntaje del examen final.

Abelardo Pardo, Feifei Han, and Robert A. Ellis (2017), proponen un modelo predictivo basado en un análisis combinado para proveer una predicción estadísticamente mejor del rendimiento académico, con esto tendremos solidas ventajas en los resultados de combinar fuentes de datos, tendremos una visión precisa de la experiencia de aprendizaje y de la misma manera poder actuar preventivamente antes debilidades encontradas. El autor explora cómo combinar datos sobre habilidades de aprendizaje auto regulado. El autor propone una metodología: los participantes (estudiantes), el contexto (de la investigación), los instrumentos (las variables de SRL, información obtenida a través del sistema de gestión de aprendizaje y el desempeño académico utilizado para supervisar el modelo). En primer lugar, el estudio utilizó información obtenida de un sistema de gestión de aprendizaje en línea. Los participantes en el estudio fueron 145 estudiantes de primer año de licenciatura, quienes se especializaron en un bachillerato de cuatro años en ingeniería en una gran universidad intensiva en investigación en un área metropolitana australiana. Entre los 145 estudiantes, el 74,5% eran mujeres, y el 24,8% eran varones. Los instrumentos utilizados fueron: 1) Las variables de aprendizaje autorregulados de los estudiantes, incluyendo los aspectos motivacionales, afectivos y cognitivos, fueron recolectadas usando un cuestionario auto informado. 2) Información sobre la interacción con los eventos de aprendizaje en línea a través del sistema de gestión del aprendizaje. 3) Desempeño académico como las marcas finales en el curso. Las marcas finales en el curso fueron utilizadas como la medida del rendimiento académico, los valores de esta variable se encontraban en el rango de 20 a 98,50 (de 100), con un valor medio de 65,50, y una desviación estándar de 16,12. La marca de paso para el curso se establece en 50, lo que significa que la puntuación promedio está por encima de la marca de paso, pero con una amplia difusión en los valores. Este escenario es bastante común en los cursos universitarios de primer año. Se usó la regresión jerárquica como técnica para generar los modelos y sus correlaciones con las variables. Se obtuvieron dos modelos, desde una perspectiva experimental se observó que el primer modelo sólo consideró las variables de aprendizaje autorreguladas como variables independientes. Los resultados muestran que sólo la ansiedad de la prueba y el aprendizaje auto-regulado negativo predijeron significativamente el rendimiento académico con un efecto pequeño [ $F(1, 143) = 6.18, p < .01, f^2 = .08$ ]. Las dos variables representaron sólo el 7% de la varianza. Del segundo modelo se observó las variables independientes adicionales que codifican el compromiso de los estudiantes con los eventos de aprendizaje en línea. Este modelo explica un 26% adicional de variación en el rendimiento académico en el curso,  $F(7, 138) = 10.44, p < .01, f^2 = 0.37$ , para un total de 32% y un gran tamaño de efecto.

S. Ikbāl, A. Tamhane, B. Sengupta, M. Chetlur, S. Ghosh, J. Appleton (2015), proponen la predicción temprana de los estudiantes de K-12 (suma de primaria y educación secundaria) en riesgo de rendimiento académico deficiente, también se refiere indistintamente a lo largo de este documento como estudiantes en riesgo, lo que permitirá poder tomar acciones para

una enseñanza personalizada. El autor contribuye en el desarrollo de un marco genérico para predecir los riesgos de desempeño académico para los estudiantes de K-12 en diferentes niveles de granularidad del currículo, tales como temas, temas dentro de los temas y conceptos dentro de los temas. Una predicción detallada de los riesgos en niveles de granularidad múltiples es potencialmente útil para los profesores, para ayudarlos en la planificación de intervenciones eficaces para los estudiantes en riesgo. El objetivo principal es predecir los riesgos de rendimiento académico que ayudarían a los docentes a planificar intervenciones personalizadas efectivas. Para ilustrar mejor el potencial para alcanzar este objetivo dentro del alcance de los datos disponibles, se eligió el siguiente conjunto de sub-tareas para el análisis y la experimentación: 1) predecir el riesgo de rendimiento del nivel de subprueba para cada estudiante, 2) predecir el riesgo de rendimiento del nivel de filamento para cada estudiante, y 3) hacer ambas predicciones lo antes posible en el viaje del k-12 de cada estudiante. En este trabajo, definimos el riesgo del nivel de subprueba como un posible fallo en la subprueba correspondiente. El riesgo de nivel de filamento es una mala puntuación potencial en el filamento o rama correspondiente. El autor propone la siguiente metodología: Primer paso se procesa los datos o información, que tiene subprocesos, los cuales son la combinación de registros fusionados. Segundo paso consiste en preparar los datos de los registros fusionados para la construcción de los modelos, así como para predicciones específicas. Los datos que se preparan son específicos para cada tarea de predicción. Los datos necesarios para el modelo de construcción incluyen los siguientes: 1) una lista de los estudiantes que podrían ser utilizados para la formación, 2) las características de entrada extraídas de los registros de los estudiantes de cada estudiante en la lista de entrenamiento, y 3) el valor objetivo para cada estudiante en la lista de entrenamiento. Las características de entrada dependen del nivel de grado al que se considera que pertenece el estudiante. Para cada estudiante, extraemos todos los puntajes por debajo del nivel de grado actual del estudiante y los utilizamos junto con la información demográfica y de comportamiento como las características de entrada. Tenga en cuenta que, durante el entrenamiento, los estudiantes considerados en los datos de entrenamiento pueden tener puntuaciones de prueba disponibles para los grados más altos, pero sólo las puntuaciones por debajo del nivel de grado al que los estudiantes se consideran pertenecen se utilizan como las características de entrada. La generación de valor de final de predicción depende puramente de la tarea de predicción que se está considerando. La puntuación obtenida en el grado/prueba/subprueba/filamento (tema) correspondiente se extrae del registro estudiantil y se compara con el umbral específico de riesgo asignado para la tarea correspondiente, y se genera un valor de destino binario "en riesgo" o "sin riesgo". El tercer paso, consiste en el manejo de la falta de datos, caso que ocurre en muchos data sets. Por ejemplo, durante la construcción del modelo, primero si no hay información de objetivo para un estudiante particular en la lista de entrenamiento, entonces descartamos a ese estudiante del entrenamiento. Seguidamente en este paso, imputamos valores de aquellos datos que faltan que están dentro de los límites aceptables. El

entrenamiento recibe las características de entrada (como se describe en la subsección anterior) en forma de matriz, con filas correspondientes a los estudiantes y columnas correspondientes a las características (puntuaciones y otra información del estudiante). En esta matriz, podamos las filas y columnas donde la cantidad de datos faltantes está más allá de un límite de umbral, en este trabajo, se utilizó un valor umbral del 80% de los datos faltantes. En este trabajo, se utilizó un valor umbral del 80% de los datos faltantes, Los detalles del conjunto final de características que se usan para el entrenamiento después de todos estos pasos de procesamiento también se almacenan finalmente junto con el modelo. Si durante la predicción faltan más del 80% de las características requeridas, simplemente evitaremos hacer predicciones para el estudiante correspondiente. El cuarto paso consiste en un procesamiento adicional de los datos. El autor propone antes de alimentar las características en el clasificador, los datos necesitan ser procesados más a fondo para la limpieza, la numeración, y la normalización. Las características del estudiante son típicamente de varios tipos tales como, numérico, cadena valorada, nominal, y binario. Estimamos el tipo de cada función según los valores observados en la matriz de funciones de entrada de formación. Puesto que la mayoría de los clasificadores aceptan solamente valores numéricos, cada característica se debe transformar para adaptarse al clasificador. En el último paso se genera la predicción, que se da por el sistema de predicción, donde se usó la implementación clasificadores de IBMSPSS y WEKA aplicando clasificadores binarios. Lo que obtenemos de los modelos de predicción (clasificadores binarios en nuestro caso) son los valores de probabilidad para la clase de riesgo con valores que varían de 0 a 1. Un umbral aplicado a estas probabilidades decidiría la clase predicha de la clase "en riesgo" si el valor de probabilidad está por encima del umbral y la clase "sin riesgo" de otra manera. Desde una perspectiva experimental se observó, que curiosamente, en las tablas, la mayoría de los números de precisión están por encima de 0,80, con muchos de ellos cerca o por encima de 0,90, lo que apunta al hecho de que nuestro sistema es capaz de hacer predicciones de riesgo bastante precisa para los estudiantes en diversas tareas de predicción. Tenga en cuenta que los riesgos que estamos prediciendo corresponden a los riesgos de fracaso en caso de subpruebas (sujetos) y los riesgos de puntuación deficiente en caso de hebras (temas específicos).

Cortés, Colmenar, Hidalgo, Sánchez, Santonja y Villanueva (2016), proponen un modelo de red aleatoria para realizar la creación de modelo predictivo, el contexto de estudio es el bachillerato en España, donde según el nivel se remueve a los estudiantes. El modelo de red consiste en el siguiente ciclo de vida: 1) Los datos disponibles, 2) los supuestos (consisten en identificar cada estado estudiantil mediante la codificación de todas las etiquetas posibles de los estudiantes), 3) Descripción de la red (se define el modelo de red tomando en cuenta los supuestos) y finalmente 4) la evolución de la red (donde se describe como la red evoluciona en el tiempo, pudiendo comprobar si hay algún cambio de estado del estudiante).

Para resolver el problema el modelo de red aleatorio propuesto se basa en 46 parámetros diferentes, como consecuencia, tratamos con un amplio espacio de búsqueda de posibles valores. Los resultados de los valores del parámetro se investigan en un número enorme de combinaciones que se explorarán para encontrar los valores óptimos del parámetro. Así, para encontrar los mejores parámetros, se pueden elegir dos enfoques. Por un lado, se puede seleccionar algoritmos de optimización deterministas clásicos como la búsqueda exhaustiva, que devolverá la solución óptima. Sin embargo, esto no es posible dentro de un tiempo razonable y considerando también el esfuerzo computacional. Por otro lado, se plantea seleccionar una metaheurística para realizar la búsqueda. Este tipo de técnicas inteligentes son capaces de guiar la búsqueda a través del espacio de la solución, reduciendo el número de evaluaciones y, por tanto, obteniendo tiempos de ejecución aceptables. Se seleccionó una metaheurística denominada Evolución Diferencial (DE) como nuestro algoritmo de búsqueda ya que es una técnica muy adecuada para problemas de optimización de valor real. Lográndose así que el algoritmo DE minimiza la función objetiva que diseñamos para este problema. En primer lugar, luego que se ha estimado los parámetros que mejor se ajustan a los datos reales (mostrados en la tabla 1) en la red aleatoria, sustituimos el conjunto de parámetros que proporcionó el menor Fitness (función objetiva minimizada) (15,04538). En segundo lugar, se realizó 5000 simulaciones de la red aleatoria (los parámetros son constantes para cada simulación), con el fin de obtener la evolución de los resultados académicos de los estudiantes de bachillerato español durante los años académicos  $t = 2009 - 2010$ ,  $2012 - 2013$ . Debido al azar intrínseco de la evolución de la red aleatoria, las simulaciones serán diferentes. Además, teniendo en cuenta que sólo tenemos 300 estudiantes en nuestra red, las simulaciones pueden ser muy diferentes. En tercer lugar, se calculó la media, la mediana y el 95% de intervalo de confianza por percentiles 2,5 y 97,5 en cada instante de las simulaciones obtenidas en el paso 2 (5000 conjuntos de datos similares a la tabla 1 para los próximos años académicos 2009 – 2013). Estos intervalos de confianza nos dan la predicción de la evolución de los resultados académicos de los estudiantes de Bachillerato Español (por género, nivel académico y si lo hacen o no promueven) durante los años académicos  $t = 2009 - 2010$ ,  $2012 - 2013$ . Repetimos los primeros y segundos pasos del procedimiento anterior para la segunda menor Fitness (15,31218) y nos unimos a las salidas del modelo con las salidas del modelo dadas por el menor Fitness. Realizando el paso 3 con estas 10 000 simulaciones obtenemos medios muy similares, medianos e intervalos de confianza. Repitiendo el proceso antedicho para los 3, 4 y 5 menos aptitud (15,32896, 15,44912, 15,45847, respectivamente), los medios correspondientes, los mediadores y los intervalos de confianza de las simulaciones agregadas 15 000, 20 000 y 25 000, son muy similares (véase el apéndice b, tablas b. 11 y b. 12 correspondientes al primer conjunto de simulaciones 5000 y 10 000, respectivamente). Desde una perspectiva experimental, los resultados académicos de los estudiantes de bachillerato en el curso académico 2009 – 2010, datos que no pudieron ser utilizados inicialmente para adaptarse al modelo porque no estaban disponibles en ese momento, permiten comparar las

predicciones obtenidas de nuestro modelo con los nuevos datos reales. La predicción obtuvo un intervalo de confianza del 95% y los resultados académicos reales correspondientes a las primeras y segundas etapas del bachillerato, tanto en las escuelas secundarias estatales como privadas en toda España durante el curso académico 2009 – 2010. Cada fila muestra la tasa de niñas/niños que promueven (GI/BI) y no promueven (GI/BI) para cada nivel  $i = 1, 2$ .

En conclusión, solo Wang et al. (2015), propone utiliza información de otro tipo a otros autores, utilizando información de que transmiten los sensores de los Smartphone, utiliza la técnica validación cruzada, para determinar los parámetros y los pesos de estos debido a la gran cantidad de información que se posee, todo esto para generar el modelo predictivo, mientras que Pardo et al. (2016), propone un análisis profundo de los datos es decir enfocarlo pedagógicamente, para una buena posterior interpretación utilizando información de un sistema de aprendizaje en línea. Pardo et al. (2017), propone una idea novedosa donde genera su modelo predictivo haciendo uso de un análisis combinado entre un sistema de gestión de aprendizaje sumando los datos de aprendizaje autorregulado de los estudiantes que son obtenidos con un cuestionario mientras que Ikbali et al. (2015), observa lo beneficioso que es fusionar todas las diferentes fuentes de información en una sola, y aplican diversos métodos para obtener la mejor calidad de los datos, utilizando una predicción más personalizada, donde se analiza hasta los temas que tienen los estudiantes. Cortés et al. (2016) al igual que Rui et al. (2015), aplican técnicas para obtener los valores óptimos de los parámetros en su modelo de red aleatorio, pero aplicando una metaheurística ya que computacionalmente probar cada parámetro en el modelo de red sería totalmente inviable, así se obtiene minimizar la función objetivo, y mejorando la función óptima posible.

# CAPÍTULO III: APORTE

## 3.1 Descripción

El diseño de esta arquitectura nos permite generar tanto nuestro modelo predictivo gracias a la fase de entrenamiento de nuestra red neuronal, para seguidamente la implementación de un aplicativo que nos permite validar la precisión que posee nuestra red neuronal artificial, así como la predicción que realicen los estudiantes universitarios.

Una de las secciones importante de esta investigación es generar el modelo predictivo basado en una arquitectura de perceptrón multicapa con back propagation, para esto será necesario realizar cuatro fases importantes. En primer lugar, debe extraerse la información de una fuente de datos, lo cual se simulará conectando un aplicativo móvil a una fuente de datos. En segundo lugar, se debe implementarse el proceso de entrenamiento de nuestra red neuronal con una arquitectura perceptrón multicapa con back propagation. En tercer lugar, debe formularse el modelo predictivo según lo genere nuestra red neuronal, y presentando los resultados del proceso. Finalmente, el modelo predictivo debe ser validado con los conjuntos de datos prueba para la supervisión de las salidas de nuestra red neuronal.

### 3.1.1 Componentes del aporte

#### a) Origen de Datos

Este componente es la base de datos principal de nuestra arquitectura, tiene la función de almacenar toda la información que fluya en la interacción de los componentes de nuestro modelo. Este componente se subdivide en dos.

##### **BD del Sistema**

Este conjunto de tablas dentro de tienen la funcionalidad de almacenar la información que se genera en la interacción de los usuarios, historiales que generan una predicción de la red neuronal entrenada, así como también la información necesaria para el funcionamiento de nuestro aplicativo de prueba de la red.

##### **BD de Entrenamiento**

Estos conjuntos de tablas tienen la función de almacenar toda la información que se realizó el entrenamiento de nuestra red neuronal, informes de actualización de pesos de la red, errores, iteraciones, información del modelo predictivo.

#### b) Data de Entrenamiento

Este componente contiene nuestra data de entrada para nuestra red neuronal, la que se utiliza para realizar el entrenamiento. Esta información es la data que se obtuvo



del registro de un conjunto de alumnos, junto a un conjunto de encuestas que se realizó.

**c) Módulo de aplicaciones**

Este componente tiene una función importante, contiene los módulos desarrollados necesarios para la creación del modelo predictivo y generar la predicción para nuevos patrones.

**Módulo de red neuronal**

Este módulo tiene la finalidad de poder procesar el entrenamiento de nuestra red neuronal, es decir ejecutará las iteraciones según la data de entrenamiento según se le indico, y generar el modelo predictivo de clasificación. Cabe resaltar que el diseño de nuestra red neuronal está incluido en este módulo.

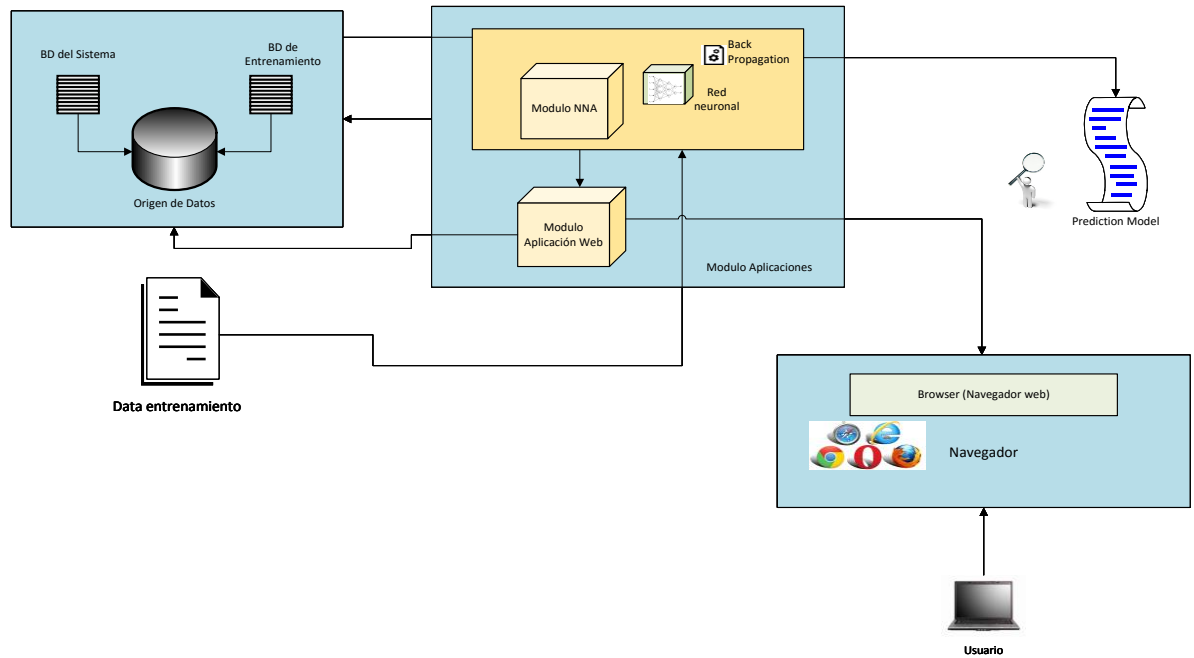
**Modulo Aplicación Web**

Este módulo tiene la finalidad de recibir las peticiones que realiza nuestros usuarios, la seguridad de la aplicación, y las funcionalidades del aplicativo, cabe resaltar que contiene la lógica de negocio para poder realizar el reconocimiento de nuevos patrones ingresados.

**d) Modelo predictivo**

Este componente, es el resultado que se obtiene a través del entrenamiento de nuestra red neuronal, con nuestra data supervisada. Este componente permite evaluar el proceso de entrenamiento, conteniendo los errores, las matrices de pesos según los patrones de entrenamiento. Este componente permite visualizar resultados para poder realizar una evaluación y validación.

### 3.1.2 Modelo del aporte



**Figura 3: Arquitectura propuesta**

Esta arquitectura planteada está compuesta por: el origen de datos, el módulo de aplicaciones, el modelo predictivo, el componente cliente, a continuación, explicaremos la comunicación entre estos componentes.

Iniciamos con el uso de la data de entrenamiento, este componente contiene la data inicial para el entrenamiento de nuestra red neuronal, seguidamente esta data es procesada por nuestro módulo de red neuronal, el cual inicia el proceso de utilizando el algoritmo back propagation, luego del entrenamiento la información que se genera en este proceso es almacenada en nuestro origen de datos de entrenamiento, así generando el modelo predictivo de clasificación, el cual se analizará y revisará para su validación de resultados.

Para la clasificación de nuevos patrones fue necesario el proceso de entrenamiento de nuestra red neuronal, ahora los usuarios del aplicativo web desarrollado, interactúan e ingresaran nuevos patrón de datos, esta petición será recibida por nuestro componente módulo web, el cual realiza una petición a nuestro módulo de red neuronal el que procesa el nuevo patrón de datos a través de nuestra red neuronal y la información de entrenamiento almacenada en nuestro origen de datos, finalmente se genera la

clasificación y se muestra la clasificación del rendimiento del curso del estudiante universitario.

### 3.1.3 Fases para la creación del aporte

Para poder generar la predicción del rendimiento académico universitario es necesario, seguir un grupo de fases para obtener los resultados. Por lo que se especificara las fases necesarias.

#### 1) Extracción y preparación de datos

Teniendo en mente que una de las principales funciones es poder generar el modelo predictivo del rendimiento académico universitario, a partir de los datos acerca de cómo se organiza un alumno universitario. Los cuales para este estudio se obtienen mediante encuestas a 30 estudiantes, teniendo estas almacenadas en documentos de tipo texto.

Se utilizó data de estudiantes del Sistema único de matrícula de la UNMSM, almacenando esta información en archivos de tipo texto.

Finalmente se acoplo la información de las encuestas con la información recogida del sistema de matrícula de la universidad teniendo así completa nuestra data de entrenamiento para nuestra de red neuronal.

Es necesario definir la salida del modelo predictivo y predicciones del rendimiento académico universitario mediante el aplicativo, ya sabiendo que este indicador está directamente relacionado al riesgo o rendimiento académico.

NOTAS	VALORACIÓN
<b>16-20</b>	Aprendizaje excelente
<b>14-15</b>	Aprendizaje bueno
<b>11-13</b>	Aprendizaje regular
<b>10-0</b>	Aprendizaje deficiente

TABLA 5. Categorización del Rendimiento Académico (según la DIGEBARE del Ministerio de Salud)

## 2) Entrenamiento de la red neuronal


La red neuronal se implementó en un módulo de red neuronal el cual se conectó a nuestra de entrenamiento y así procesó los datos que se encuentren allí, de esta manera se entrenó a nuestra red neuronal.

Este proceso de enteramiento se llevará a cabo automáticamente por nuestra red neuronal con el algoritmo de Back propagation, basándose en reducir el error en todas capas ocultas, y acercarse a valor óptimo.

Para poder realizar el entrenamiento de nuestra red neuronal fue necesario realizar un conjunto de procedimientos, los cuales fueron:

### Diseño de la red neuronal

El diseño de nuestra red nuestra red neuronal multicapa posee tres capas, la capa de entrada, la capa oculta y la capa de salida. La capa de entrada contiene cuatro neuronas, esta se encargó de recoger la data de entrenamiento, generando salidas que serán las entradas para capa oculta compuesta por tres neuronas, que de la misma manera generó las entradas para nuestra capa salida que se compuso de dos neuronas en dicha capa, esta se encargó de generar las salidas de nuestra red neuronal.




**Figura 4: Diseño de la red neuronal**

## Proceso de entrenamiento de la red neuronal

El proceso de entrenamiento de nuestra red neuronal se utilizó el algoritmo de back propagation. Para realizar el entrenamiento de nuestra red neuronal con el algoritmo seleccionado fue necesario ejecutar dos fases necesarias, primero se hace el proceso de propagación hacia adelante y finalmente la retro-propagación.

### 1) Propagación hacia adelante

Como vemos en el diseño de nuestra red neuronal (Figura 5), cada capa recibe datos de entrada para luego generar una salida, las cuales sirven como datos de entrada para las capas posteriores. Se usó un conjunto de fórmulas para poder realizar los cálculos de nuestras salidas lineales, y función sigmoide de cada neurona.



**Figura 5: Salidas de propagación hacia adelante**

Como vemos en la figura 6, cada neurona de nuestras capas calcula dos valores  $V_i$  y  $Y_i$ , donde el primero calcula la salida lineal de las entradas de las capas anteriores y la segunda calcula la función sigmoide del valor  $V_i$ .

$$V_j^k = \langle W_j^k, X \rangle = \sum_{i=0}^n W_{ji}^k X_i \dots\dots\dots (1)$$

$$Y_j^k = \phi(V_j^k) = \frac{e}{1+e^{-bV_j^k}} - 1 \dots\dots\dots (2)$$

Donde:


- $k$ : Capa de la red
- $j$ : Neurona actual,  $x$ : entradas,
- $i$ : Índice de las entradas
- $b$ : Constantes acumuladas
- $W_{ji}$ : Es la matriz de pesos de cada capa.

De esta manera se calculó todas las salidas lineales y las funciones sigmoides de cada neurona de nuestra red, así se calculó las salidas finales de nuestra red, lo que posteriormente se evaluó con las salidas deseadas, para obtener el error de la red.

## 2) Retro propagación

Esta fase es fundamental para poder realizar el entrenamiento de nuestra red, es decir poder actualizar las matrices de pesos que se encuentran en cada una de nuestras capas, estas actualizaciones de pesos se realizan en base a los errores que genera la red en la capa salida.

Para realizar la retro propagación lo primero que se debe realizar es calcular el error de las neuronas de la capa de salida en comparación con las salidas deseadas. Existen dos formas de calcular los errores, podemos calcular el error por cada neurona o calcular mediante el error cuadrático de nuestra red.



**Figura 6: Error en capa de salida**

Error por neurona:

$$e_j = Y_i - Y_d \dots \dots \dots (1)$$

Error cuadrático instantáneo:

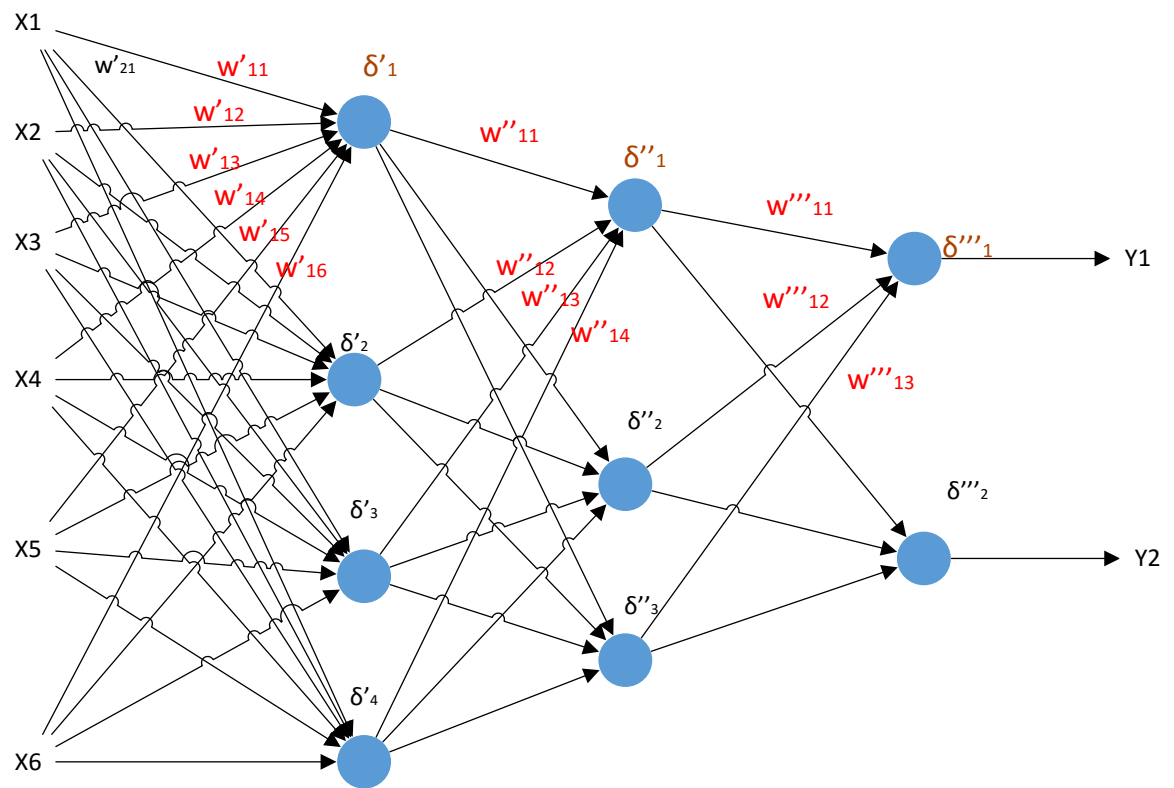
$$\xi = \frac{1}{2} \sum_{j=1}^M e_j^2(n) \dots \dots \dots (2)$$

Donde:

- $e_j$ : Error de la neurona j
- $Y_j$ : Salida de la neurona j
- $Y_d$ : Salida deseada de la neurona j
- $\xi$ : Error cuadrático instantáneo
- M: Cantidad de neuronas de la capa de salida.
- j: Índice de la neurona
- n: Número de iteración actual de entrenamiento de la red

Luego de que se calculó los errores, se procede a actualizar los pesos, los cuales se realizan en relación al error calculado.

En el algoritmo BP, el error calculado desde la capa de salida se retro propaga en todas las capas anteriores. Para poder actualizar las matrices de pesos es necesario calcular la gradiente ( $\delta$ ) de cada una de nuestras neuronas de cada capa.



**Figura 7: Propagación hacia atrás**

Aplicación de la gradiente:

$$\Delta W_{ji}(n) = -\mu \frac{\partial \xi(n)}{\partial W_{ji}(n)} \dots \dots \dots (1)$$

Despejando:

$$\frac{\partial \xi(n)}{\partial W_{ji}(n)} = \frac{\partial \xi(n)}{\partial e_j(n)} \cdot \frac{\partial e_j(n)}{\partial Y_j(n)} \cdot \frac{\partial Y_j(n)}{\partial V_j(n)} \cdot \frac{\partial V_j(n)}{\partial W_{ji}(n)} \dots \dots \dots (*)$$



$$\frac{\partial V_j(n)}{\partial W_{ji}(n)} = \frac{\partial \sum_{i=0}^N W_{ji}(n) \cdot Y_i(n)}{\partial W_{ji}(n)} \dots\dots\dots (**)$$

$$\frac{\partial V_j(n)}{\partial W_{ji}(n)} = Y_i(n) \dots\dots\dots (***)$$

Gradiente de error local instantánea (Delta)

$$\delta_j = \frac{\partial \xi(n)}{\partial Y_j(n)} \cdot \frac{\partial Y_j(n)}{\partial V_j(n)} \dots\dots\dots (2)$$

Derivada de la función de activación simétrica

$$\frac{\partial Y_j(n)}{\partial V_j(n)} = \frac{\partial \left\{ \frac{2}{1+e^{-V_j(n)}} - 1 \right\}}{\partial V_j(n)} \dots\dots\dots (*)$$

$$\frac{\partial Y_j(n)}{\partial V_j(n)} = \frac{1}{2} (Y_j(n) + 1) \times (Y_j(n) - 1) \dots\dots\dots (**)$$

Aplicación de la gradiente

$$\Delta W_{ji}(n) = \mu \delta_j(n) \cdot Y_i(n) \dots\dots\dots (3)$$

Despejando obtenemos la gradiente

$$\delta_j = \frac{\partial \xi(n)}{\partial Y_j(n)} \frac{1}{2} (1 + Y_j(n)) \cdot (1 - Y_j(n)) \dots\dots\dots (*)$$

La gradiente varía en cuanto a la capa en la que nos encontramos, como sabemos para calcular las gradientes de alguna capa se necesita la capa posterior, estando en la capa de salida no tenemos gradiente posterior, por lo que se usa el error de la salida para calcular la gradiente de la capa de salida.

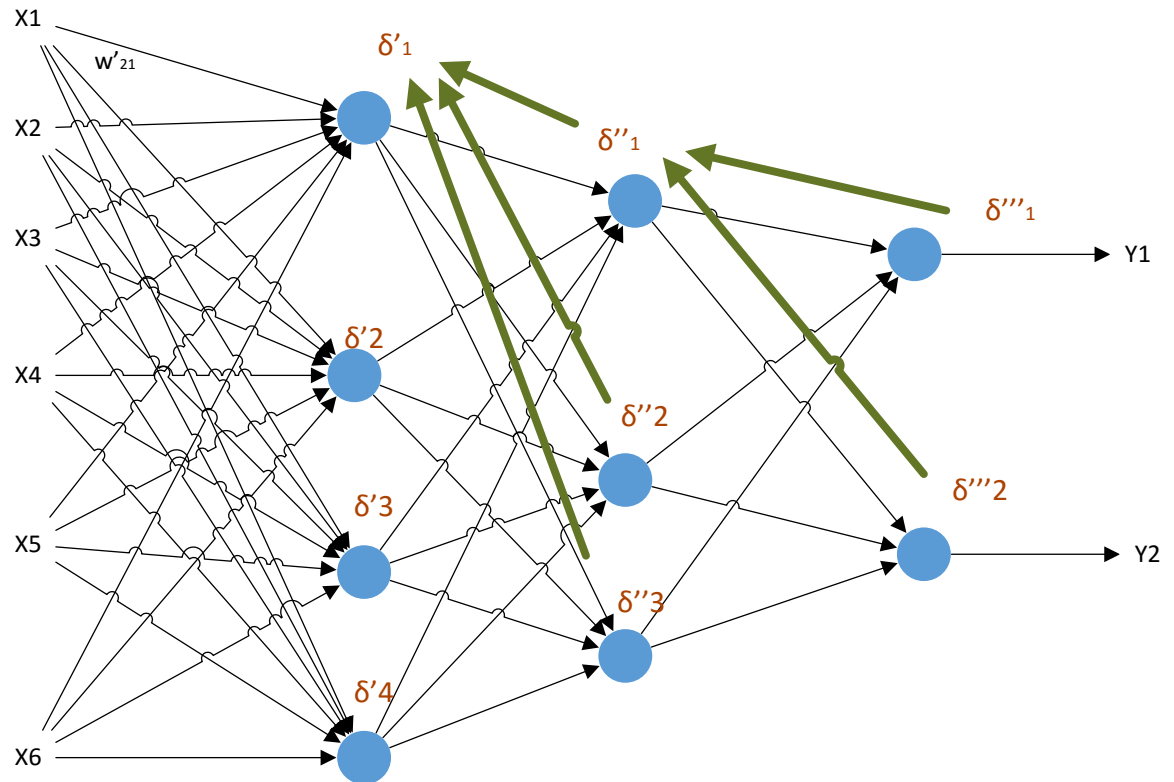
Calculo de gradiente para capa de salida, en nuestro caso la capa III.

$$\delta_j^{III} = \frac{1}{2} e_j(n) \cdot (1 + Y_j(n)) \cdot (1 - Y_j(n)) \dots\dots\dots (**)$$

Así reemplazamos la gradiente fórmula para actualizar los pesos de nuestra última capa, o llamada también capa de salida.

$$\Delta W^{III}_{ji}(n) = n e_j(n) \cdot (1 + Y^{III}_j(n)) \cdot (1 - Y^{III}_j(n)) \cdot Y^{II}_i(n)$$

Las fórmulas de gradiente y la actualización de los pesos mostrados anteriormente funcionan para nuestra capa de salida, tratando de un caso excepcional, ya que no existe una gradiente de capa posterior, es decir no se necesita calcular una gradiente posterior ya que no existe capa posterior.



**Figura 8: Retroceso del error a través de las gradientes**

Para la capa oculta o nuestra segunda capa en nuestro caso, tendríamos la siguiente formula de calcular el delta de los pesos.

$$\Delta W_{ji}^{II}(n) = \mu \delta_j^{II}(n) \cdot Y_i^I(n) \dots\dots\dots (1)$$

El cálculo de la gradiente para este caso sería la siguiente:

$$\delta_j^{II} = \sum_k \delta_k^{III} W_{ki}^{III} \cdot \frac{1}{2} \cdot (1 + Y_j^{II}(n)) \cdot (1 - Y_j^{II}(n)) \cdot Y_i^I(n) \dots (*)$$

Donde:

$n$ : Número de iteración del entrenamiento.

$k$ : El número de la neurona de la capa donde posterior

De esta manera podemos se obtiene la formula general para la actualización de las capas de nuestra red neuronal.

$$\Delta W_{ji}^I(n) = \eta \sum_k \delta_k^{III} W_{kj}^{III} \cdot (1 + Y_j^I(n)) \cdot (1 - Y_j^I(n)) \cdot Y_i^I(n)$$

$$\Delta W_{ji}^p(n) = \eta \langle \delta_k^{(p+1)} \cdot W_{kj}^{p+1} \rangle \cdot (1 + Y_j^p(n)) \cdot (1 - Y_j^p(n)) \cdot Y_i^{p-1}(n) \dots (2)$$

Donde:

$\eta$ : Es la acumulación de todas las constantes incluido el valor 1/2 antes visto.

$p$ : Número de la capa es que estamos calculando.

### 3) Construcción del entorno para realizar el entrenamiento de la red neuronal

Para poder crear la aplicación que permita entrenar nuestra red neuronal, se utilizó un entorno de prueba, JUnit, este conjunto de bibliotecas nos permitió agilizar el proceso de entrenamiento de nuestra red neuronal, así mismo poder tener la conexión a nuestra base de datos para poder almacenar toda la información generada en este proceso. La construcción de este proceso se realizó utilizando Java 1.8, conectándonos a una base de datos PostgreSQL.

Las variables que se tomaron en cuenta en nuestro procesamiento de red neuronal, de las cuales se hará una elección de las óptimos y que generen los mejores resultados son las siguientes:

Área del curso	ACC	Valores	Valor	Normalizado
		Cursos gestión	1	0.25
		Cursos matemática y operativa	2	0.5
		Cursos redes y hardware	3	0.75
		Cursos software	4	1
Tipo del curso	TCC	Valores	Valor	Normalizado
		Teórico	1	0.333333333
		Practico	2	0.666666667
		Teórico y Practico	3	1
Agrado del curso	AGC	Valores	Valor	
		Bajo	1	0.333333333
		Medio	2	0.666666667
		Alto	3	1

Horas lectura	HLD	Valores	Valor	Normalizado
		1 hora	1	0.25
		2 horas	2	0.5
		3 horas a 4 horas	3	0.75
		5 horas a mas	4	1
Horas practica	HPD	Valores	Valor	Normalizado
		1 hora	1	0.25
		2 horas	2	0.5
		3 horas a 4 horas	3	0.75
		5 horas a mas	4	1
Horas de reunión semanal	HRS	Valores	Valor	Normalizado
		1 hora	1	0.25
		2 horas	2	0.5
		3 horas	3	0.75
		4 horas a mas	4	1
Horas de ocio	HDD	Valores	Valor	Normalizado
		1 hora	1	0.25
		2 horas	2	0.5
		3 horas a 4 horas	3	0.75
		5 horas a mas	4	1

TABLA 6: CARACTERISTICAS PARA EL MODELO

#### 4) Construcción del aplicativo de predicción de rendimiento académico universitario

Para el realizar el desarrollo del aplicativo de predicción de rendimiento académico universitario se utilizó una metodología ágil para obtener un producto en menor tiempo sin perder la calidad necesaria.

##### Metodologías Agiles

##### 1) Extreme Programming (XP)

Se realizará este modelo de programación ya que necesitábamos resultados más directos y reduciendo cualquier tipo de burocracia que pueda existir en el momento de la programación.

Se eligió utilizar XP ya que posee un conjunto de características importantes para la programación de nuestro software.

- Desarrollo iterativo e incremental: pequeñas mejoras, unas tras otras.
- Pruebas unitarias continuas.

- Programación por parejas: se recomienda que las tareas de desarrollo se lleven a cabo por dos personas en un mismo puesto.
- Corrección de todos los errores antes de añadir nueva funcionalidad.
- Refactorización del código, es decir, reescribir ciertas partes del código para aumentar su legibilidad y mantenibilidad, pero sin modificar su comportamiento.

Se utilizó las siguientes fases de la metodología XP:

- Fase de planeación: Esta fase inicia con las historias de usuario que describen las características y funcionalidades del software. El cliente asigna un valor o prioridad a la historia, los desarrolladores evalúan cada historia y le asignan un costo el cual se mide en semanas de desarrollo.
- Fase de diseño: El proceso de diseño debe procurar diseños simples y sencillos para facilitar el desarrollo. Se recomienda elaborar un glosario de términos y la correcta especificación de métodos y clases para facilitar posteriores modificaciones, ampliaciones o reutilización del código. Anteriormente este proceso se apoyaba en el uso de tarjetas CRC (Colaborador-Responsabilidad-Clase) la cual identifica las clases orientadas a objetos que son relevantes para el incremento del software.
- Fase de codificación: En ésta fase los desarrolladores deben diseñar las pruebas de unidad que ejercitarán cada historia de usuario. Después de tener las pruebas, los desarrolladores trabajarán en parejas para concentrarse en lo que debe implementarse para pasar la prueba de unidad.
- Fase de pruebas: Las pruebas de unidad deben implementarse con un marco de trabajo que permita automatizarlas, con la finalidad de realizar pruebas de integración y validación diarias, esto proporcionará al equipo un indicador del progreso y revelarán a tiempo si existe alguna falla en el sistema.

## 2) Scrum

Se utilizó este proceso ágil y liviano ya que nos permitió administrar y controlar el desarrollo del software. Una de las características que buscamos es obtener un software de calidad.

Con Scrum definimos un conjunto de prácticas y roles que se tomaron como punto de partida, definiendo, así como será nuestro proceso de desarrollo del software, los roles son:

Rol	Definición
-----	------------


<b>SCRUMMASTER</b>	Mantiene los procesos y trabaja de forma similar al director de proyecto. Su trabajo primario es eliminar los obstáculos que impiden que el equipo alcance el objetivo del sprint. El ScrumMaster no es el líder del equipo (porque ellos se auto-organizan), sino que actúa como una protección entre el equipo y cualquier influencia que le distraiga. El ScrumMaster se asegura de que el proceso Scrum se utiliza como es debido. El ScrumMaster es el que hace que las reglas se cumplan.
<b>PRODUCTOWNER</b>	Representa a los stakeholders (interesados externos o internos). Dicho de otra manera, representa la voz del cliente. Se asegura de que el equipo Scrum trabaja de forma adecuada desde la perspectiva del negocio. El Product Owner escribe historias de usuario, las prioriza, y las coloca en el Product Backlog.
<b>TEAM</b>	Incluye a los desarrolladores. El equipo tiene la responsabilidad de entregar el producto. Un pequeño equipo de 3 a 9 personas con las habilidades transversales necesarias para realizar el trabajo (análisis, diseño, desarrollo, pruebas, documentación, etc.).
<b>STAKEHOLDERS (Clientes, proveedores, vendedores, etc.)</b>	Son un grupo de personas que hacen posible el proyecto y para quienes los proyectos producirán el beneficio acordado que justifica su producción. Sólo participan directamente durante las revisiones del sprint.
<b>ADMINISTRADORES (MANAGERS)</b>	Son las personas que establecen el ambiente para el desarrollo del producto.

Tal como nos indica Scrum utilizaremos un número de sprint, los cuales cada uno serán entre una a cuatro semanas, en donde en cada sprint se entrega una versión del software usable, las características de cada sprint vinieron dado por el Product Backlog.

### Arquitectura del Sistema

La arquitectura para nuestro sistema es la de tipo Cliente-Servidor, en donde el cliente serán los usuarios del aplicativo web en este caso estudiantes universitarios, así como el usuario que desea generar el modelo predictivo; dicha arquitectura se representa en la siguiente imagen.

En donde el cliente se encarga de hacer las peticiones a nuestro servidor el cual se encarga de enviar todo lo solicitado por el cliente, como por ejemplo el aplicativo web o a la base de datos del sistema.




**Figura 9: Arquitectura del sistema**

### Calidad del Software

El software pasó por un análisis de calidad, mediante el cual se indica si se cumplió o no con la calidad esperada de nuestro software. En este proceso de análisis de calidad se estableció un conjunto de métricas de calidad, estas métricas de calidad tuvieron que ser cumplidas para que obtener un software de calidad, estas métricas serán medidas con Sonar, plataforma de código abierto que nos permite gestionar la calidad de nuestro código fuente.

Ana María García Sánchez (2010). Sonar es una aplicación web con las siguientes características: está basada en reglas, alertas, rangos, exclusiones y configuración; permite configuración online, dispone de una base de datos y permite combinar métricas en conjunto. Sonar abarca los siguientes ámbitos de evaluación.



**Figura 10: Ámbitos de evaluación de Sonar**

## CAPITULO IV: DESARROLLO DE LA APLICACIÓN

Para la construcción del aplicativo se utilizó diversas técnicas para el proceso del ciclo de vida del software. Se utilizó un proceso de desarrollo ágil, las cuales fueron Scrum y la metodología XP como técnicas.

### 4.1 Análisis de la solución

Para poder obtener las necesidades de los estudiantes, se realizó un conjunto de encuestas, las cuales especificaremos a continuación.

#### 4.1.1 Entrevistas a estudiantes

1. ¿Existe una forma de que puedes saber cómo te ira en algún curso de tu ciclo académico?
2. ¿Te gustaría que existe un aplicativo web que te permite predecir tu rendimiento académico universitario en base a tu organización de un ciclo de la universidad?
3. ¿Desearías que el aplicativo de predicción de rendimiento académico universitario almacene tu información académica?
4. ¿Qué maneras de organizarte planificas para un ciclo de estudio, o no realizas una organización previa?
5. ¿Desearías poder hacer que el sistema aprenda en base a tus valoraciones de las predicciones que realizas?

#### 4.1.2 Resultados de las entrevistas realizadas

Las entrevistas se realizaron a un grupo de estudiantes de la facultad de ingeniería de sistema e informática de la Universidad Nacional Mayor de San Marcos. Los estudiantes se encontraban en los ciclos entre el séptimo hasta de décimo ciclo.

1. ¿Existe una forma de que puedes saber cómo te ira en algún curso de tu ciclo académico?

El 100% de los estudiantes entrevistados respondió que no poseen una forma de poder saber cómo les ira en un respectivo ciclo de estudio, ya sea herramienta página web, u otra.

2. ¿Te gustaría que existe un aplicativo web que te permite predecir tu rendimiento académico universitario en base a tu organización de un ciclo de la universidad?



El 100% de los estudiantes entrevistados que desean poder acceder a una herramienta que, mediante la información de sus cursos, la manera en que se organizan puedan saber cómo les irá al final del ciclo.

3. ¿Desearías que el aplicativo de predicción de rendimiento académico universitario almacene tu información académica?

El 70% de los estudiantes entrevistados está de acuerdo debido a que consideran que nos información crítica para ellos, consistiendo está en la información de sus cursos y sus ciclos de estudio, mientras que el 30% de los entrevistados no confía en que se maneja su información, consideran que no pueden controlar el uso que se haga con dicha información.

4. ¿Qué maneras de organizarte planificas para un ciclo de estudio, o no realizas una organización previa?

El 60% de los estudiantes entrevistados realiza una organización previa a un nuevo ciclo de estudio, horas de estudio, sin embargo, consideran que no la cumplen totalmente, mientras que el 25% solo planifica los cursos que deben llevar ya sea por créditos y otros aspectos, mientras que el 15% restante no realiza alguna planificación, sino todo se ejecuta de manera momentánea es decir al instante.

5. ¿Desearías poder hacer que el sistema aprenda en base a tus valoraciones de las predicciones que realizas?

El total de alumnos desean que estas predicciones puedan mejorarse en el tiempo por lo que están de acuerdo en aportar al sistema, consideran que es un beneficio mayor la mejora de la precisión.

#### **4.1.3 Desarrollo de Historias de Usuario**

Las historias de usuarios fueron desarrolladas como resultado de las respuestas de las entrevistas realizadas, estas historias de usuario no fueron redactas por los usuarios, pero se conservó la terminología de los estudiantes universitarios.

<b>N° de Historia:</b>	<b>01</b>
<b>Nombre de la Historia:</b>	Ingresar al sistema
<b>Fecha:</b>	28-10-2017
<b>Entrevistado:</b>	Carlos Sequen Llalire
<b>Tiempo Estimado:</b>	10 horas

<b>Descripción:</b>
<b>Se debe contener un estilo similar a los sitios web de vanguardia, para mejor experiencia. El ingreso debe ser mediante un usuario y clave</b>

<b>N° de Historia:</b>	<b>02</b>
<b>Nombre de la Historia:</b>	Registrar estudiante
<b>Fecha:</b>	29-10-2017
<b>Entrevistado:</b>	Cesar Barrantes Cáceres
<b>Tiempo Estimado:</b>	10 horas
<b>Descripción:</b>	
<b>El software me debe permitir registrarme, solicitando información personal, correo electrónico y una contraseña para poder ingresar al sistema.</b>	

<b>N° de Historia:</b>	<b>03</b>
<b>Nombre de la Historia:</b>	Registrar ciclo
<b>Fecha:</b>	16-10-2017
<b>Entrevistado:</b>	Prado Tenorio Andrés
<b>Tiempo Estimado:</b>	10 horas
<b>Descripción:</b>	
<b>El aplicativo me debe dejar registrar un nuevo ciclo de estudio, con fecha de ciclo, un nombre para el ciclo, numero del ciclo, así como el tipo de ciclo (verano, regular)</b>	

<b>N° de Historia:</b>	<b>04</b>
<b>Nombre de la Historia:</b>	Consultar ciclo
<b>Fecha:</b>	16-10-2017
<b>Entrevistado:</b>	Guiosep Tunky Cutipa
<b>Tiempo Estimado:</b>	10 horas
<b>Descripción:</b>	
El estudiante debe poder visualizar los ciclos agregados, poder editar los ciclos, y poder visualizar los cursos que contenga el ciclo, así como poder agregar un nuevo curso del ciclo.	

<b>N° de Historia:</b>	<b>05</b>
<b>Nombre de la Historia:</b>	Agregar curso
<b>Fecha:</b>	16-10-2017
<b>Entrevistado:</b>	Jhon Yaniro Coronel
<b>Tiempo Estimado:</b>	10 horas
<b>Descripción:</b>	
El aplicativo me debe dejar registrar un nuevo curso dentro de un ciclo, con la información del curso, como nombre del curso, tipo, área del curso, y horas del curso.	

<b>N° de Historia:</b>	<b>06</b>
<b>Nombre de la Historia:</b>	Consultar curso
<b>Fecha:</b>	16-10-2017

<b>Entrevistado:</b>	Cesar Barrantes Cáceres
<b>Tiempo Estimado:</b>	10 horas
<b>Descripción:</b>	
El estudiante debe poder visualizar los cursos agregados, poder editar los cursos, visualizar el historial del curso (mostrando las modificaciones y cambios de estado que haya sufrido el curso).	

<b>N° de Historia:</b>	<b>07</b>
<b>Nombre de la Historia:</b>	Generar predicción
<b>Fecha:</b>	18-10-2017
<b>Entrevistado:</b>	Leonardo Quispe Torres
<b>Tiempo Estimado:</b>	10 horas
<b>Descripción</b>	
El estudiante debe poder generar una predicción para algún curso registrado en algún ciclo. Se debe mostrar la información de la predicción y del curso de manera amigable.	

<b>N° de Historia:</b>	<b>08</b>
<b>Nombre de la Historia:</b>	Valorar predicción
<b>Fecha:</b>	20-10-2017
<b>Entrevistado:</b>	Carlos Sequen Llallire
<b>Tiempo Estimado:</b>	10 horas

<b>Descripción:</b>
<b>El aplicativo me debe dejar valorar alguna predicción, es decir indicar que la predicción fue acertada.</b>

<b>N° de Historia:</b>	<b>09</b>
<b>Nombre de la Historia:</b>	Consultar predicciones
<b>Fecha:</b>	23-10-2017
<b>Entrevistado:</b>	Ricardo Cóndor Aranda
<b>Tiempo Estimado:</b>	10 horas
<b>Descripción:</b>	
	<b>El aplicativo me debe dejar visualizar las predicciones que realice para los cursos de mis ciclos agregados.</b>

#### 4.1.4 Requerimientos funcionales

Entre los requerimientos funcionales que se puede identificar para el sistema propuesto son los siguientes que se muestra en la tabla.

Código	Nombre del requerimiento funcional
R01	El sistema permitirá el ingreso, validando el usuario y contraseña del estudiante.
R02	El sistema debe permitir a los estudiantes poder registrar un ciclo, y poder visualizar toda la información registrada.
R03	El sistema debe poder agregar nuevos cursos para los ciclos, así como poder consultar la información registrada, y poder editarla si es requerida.
R04	El sistema debe poder realizar predicción para los cursos de los ciclos, y poder visualizar las predicciones en el tiempo.
R05	El sistema debe permitir valorar las predicciones realizadas de los cursos, indicando que son correctas.

#### 4.1.5 Velocidad de proyecto

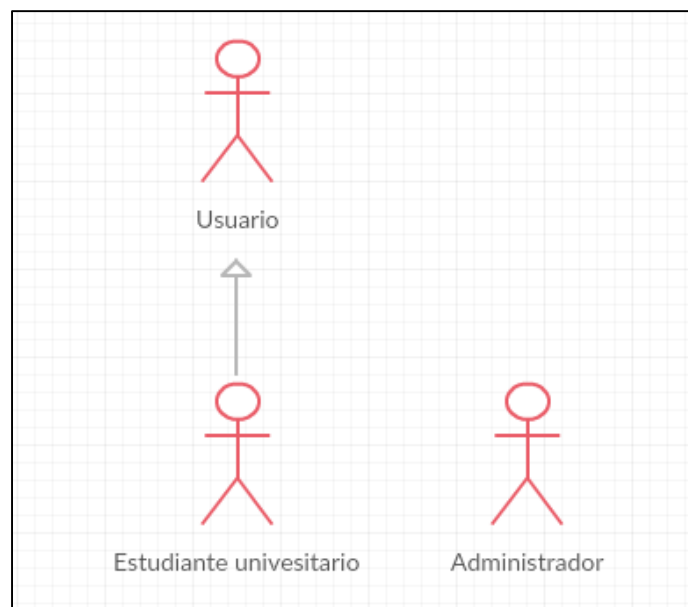
Esta medida de velocidad del proyecto es para tenerla en cuenta en cuanto al análisis de los tiempos.

	Iteración 1	Iteración 2	Iteración 3
Horas	70	50	60
Semanas	3 semanas	2 semanas	3 semanas
Horas semanales	23	25	20
Historia de usuario	3	3	3

#### 4.1.6 Actores del software propuesto

Los actores involucrados en el sistema propuesto son los que se muestran en la Tabla:

Actor	Descripción
<b>Administrador</b>	Persona que se encarga de dar mantenimiento al sistema, administrar las cuentas, perfiles de usuario.
<b>Estudiante universitario</b>	Personas cumplen la función de agregar ciclo, agregar cursos de sus ciclos, modificarlos, y realizar la predicción de sus cursos.



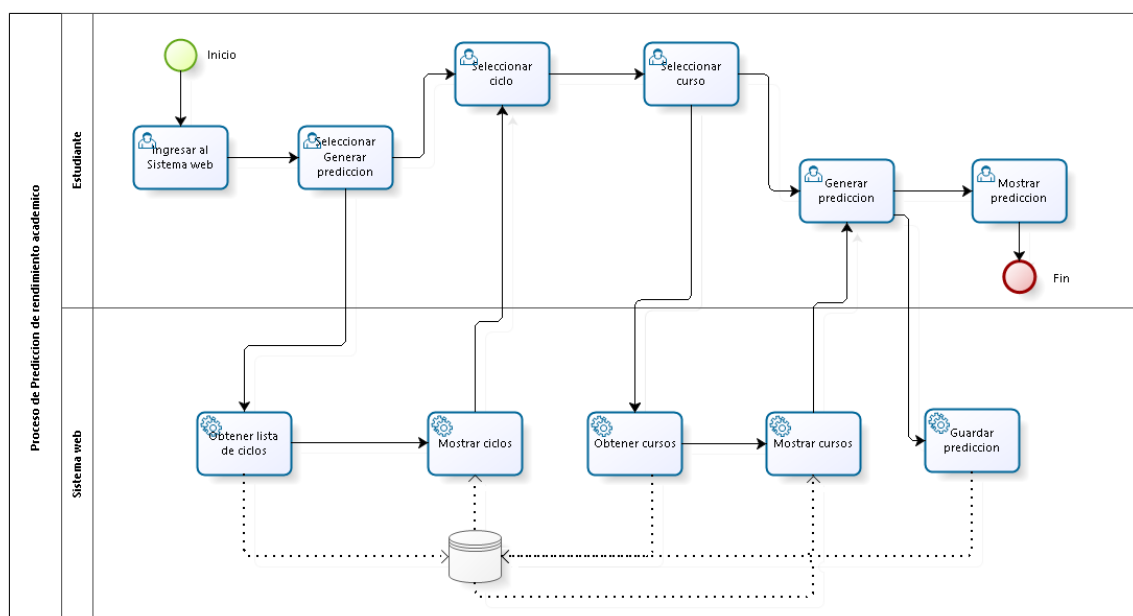
**Figura 11: Actores del sistema**

## 4.2 Diseño de la solución propuesta

### 4.2.1.1 Procesos de la solución propuesta

#### Proceso de clasificación del rendimiento académico universitario

A continuación, se mostrará y explicará el flujo de los procesos que contendrá el aplicativo web propuesto para la predicción de rendimiento académico de algún curso seleccionado por el estudiante.



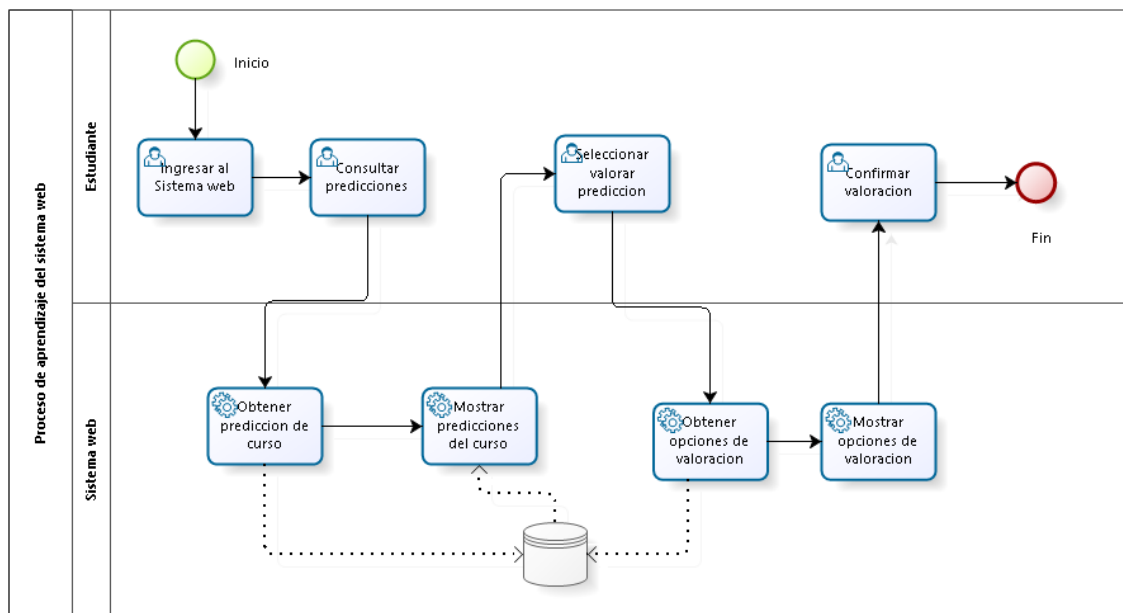
**Figura 12: BPM Proceso de clasificación**

El proceso inicia cuando el estudiante ingresa al sistema, luego seleccionara la consulta de ciclos, el sistema obtiene la lista de ciclos y lo muestra, luego selecciona la opción “mostrar ciclo”, el sistema obtiene la lista cursos del ciclo y lo muestra, luego selecciona algún curso que desee.

Finalmente, para generar la predicción del rendimiento académico, selecciona la opción “Generar predicción”, el sistema muestra los campos requeridos para calcular la predicción, y el sistema guarda la información ingresada, guarda la predicción y muestra los resultados de la predicción generada.

#### Procesos de aprendizaje del aplicativo web de clasificación

A continuación, se mostrará y explicará el flujo de los procesos que contendrá el aplicativo web propuesto el aprendizaje de sistema web propuesto, para mejorar la precisión de las predicciones del rendimiento académico.



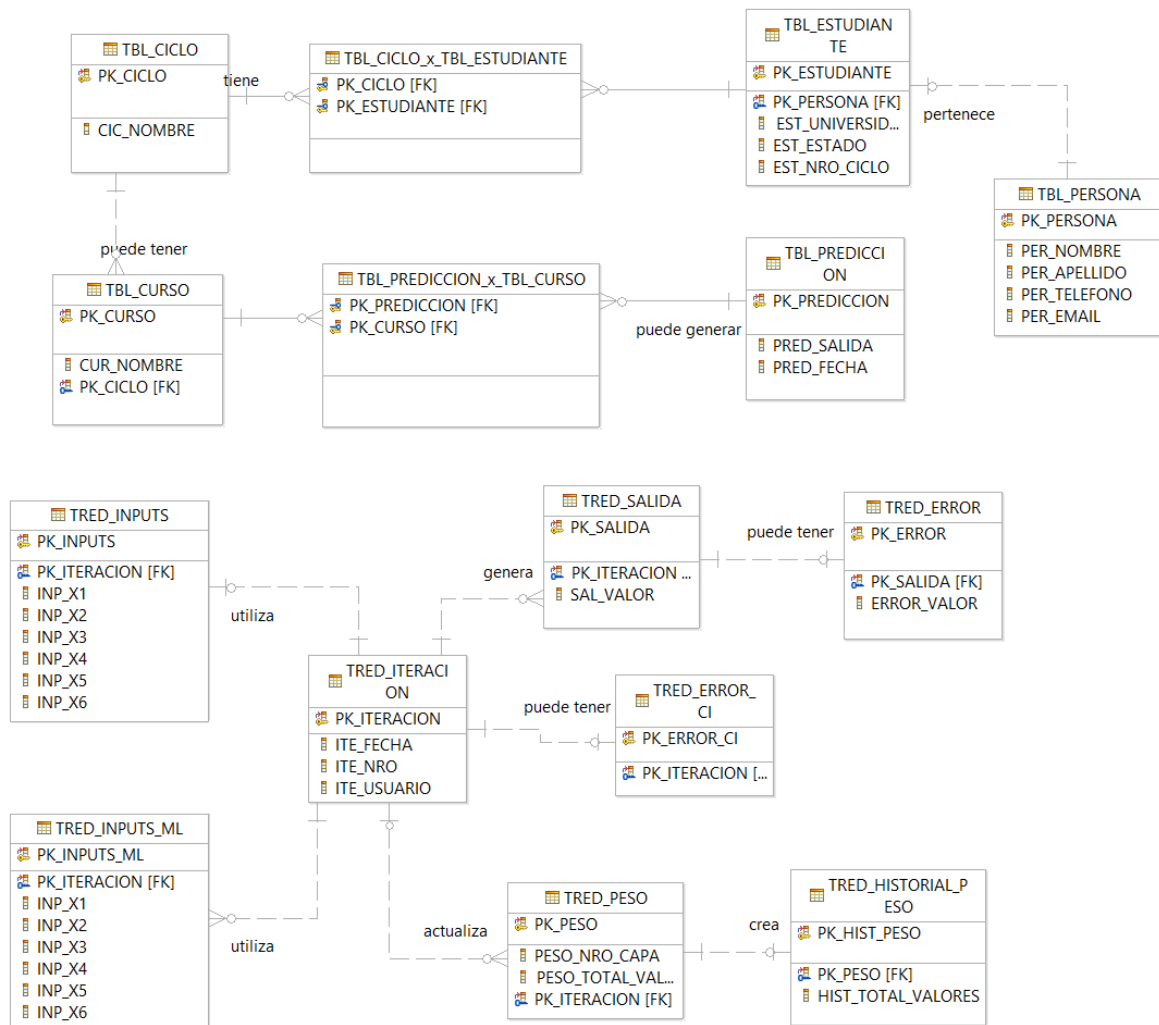
**Figura 13: BPM Proceso de aprendizaje**

El proceso inicia cuando el estudiante ingresa al sistema, luego seleccionará la opción “Consultar predicciones”, el sistema muestra las predicciones y selecciona alguna predicción hecha y seleccionará la opción “Valorar predicción”, confirmando su valoración el sistema evaluará los valores ingresados para generar esa predicción y el sistema se encargará del aprendizaje.

De esta manera se busca que las valoraciones de las predicciones se realizan finalizando el ciclo de estudio, al no ubicar este proceso al momento de generar una predicción.



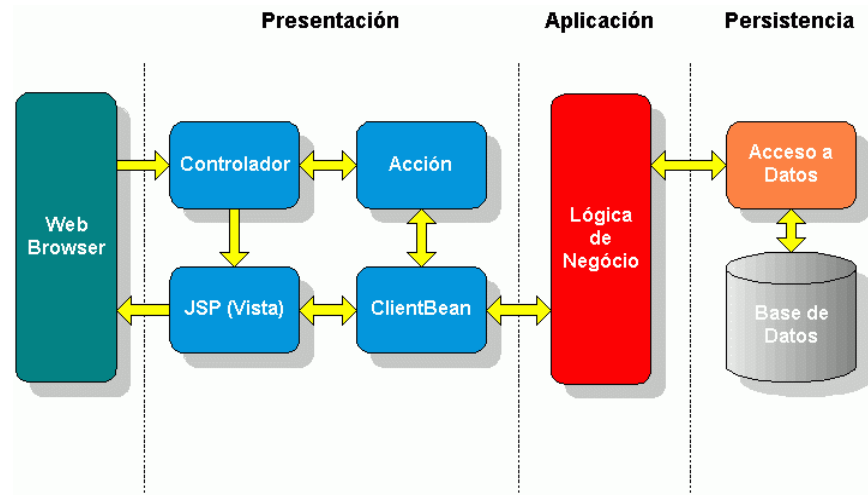
## 4.2.2 Modelo de base de datos



**Figura 14: Modelo de datos físico**

## 4.2.3 Arquitectura del aplicativo web

Para la implementación de esta solución se utilizará la arquitectura en N-Capas, debido a su diseño escalable para la incorporación de nuevos módulos y funcionalidades a futuro. La arquitectura queda dividida en 4 capas.



**Figura 15: Arquitectura del software**

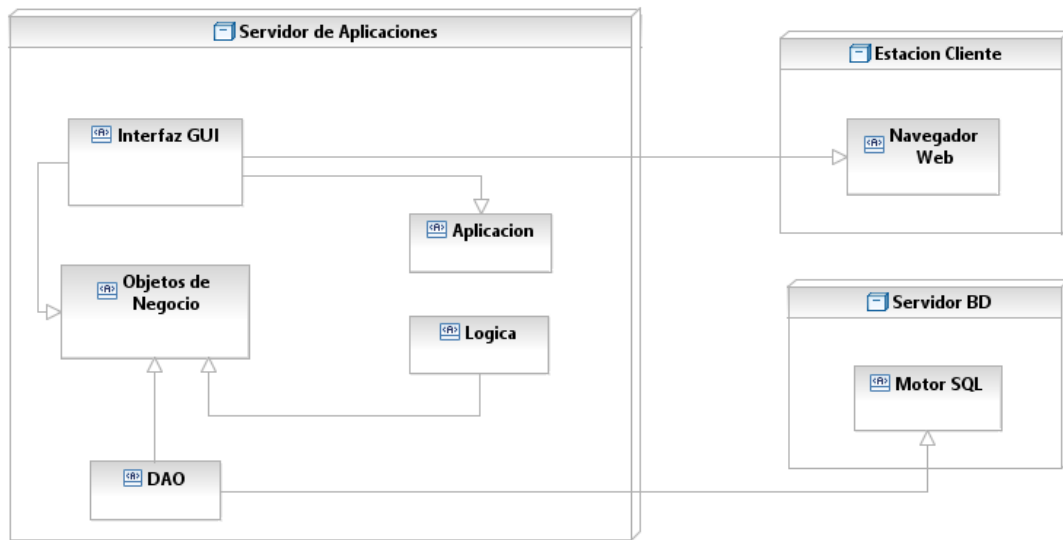
**Capa de Presentación:** Esta capa integra los elementos de la interfaz gráfica y las clases, con la lógica del comportamiento de las páginas para la interacción con el usuario.

**Capa de Aplicación:** Esta capa se encarga de delegar las solicitudes de usuario provenientes de la capa previa, hacia los módulos y clases correspondientes de la Capa de Lógica de Negocio, sin involucrar la implementación en líneas de código de dicha solicitud. Asimismo, actúa como fachada para futuras implementaciones de integración con otros dispositivos, plataformas y sistemas a través de aplicaciones como servicios Web.

**Capa de Lógica:** Esta capa sigue la línea de trabajo de la entidad Modelo del patrón MVC. Interactúa con la capa de base de datos de acuerdo con el tratamiento deseado de la información intercambiada.

**Capa de Acceso a Datos:** En esta capa se ubicarán las clases DAO y librerías de conexión encargadas de administrar operaciones CRUD (Create – Read – Update -Delete) y sentencias SQL a nivel de base de datos.

#### 4.2.4 Diagrama de despliegue del sistema



**Figura 16: Diagrama de despliegue de la solución propuesta**


**Estación cliente:** Este nodo representa al navegador Web de la máquina cliente, desde el cual se realiza la conexión al sistema.

**Servidor Web y de Aplicación:** En este nodo residen los archivos del código fuente con la lógica de negocio estructurada en capas.

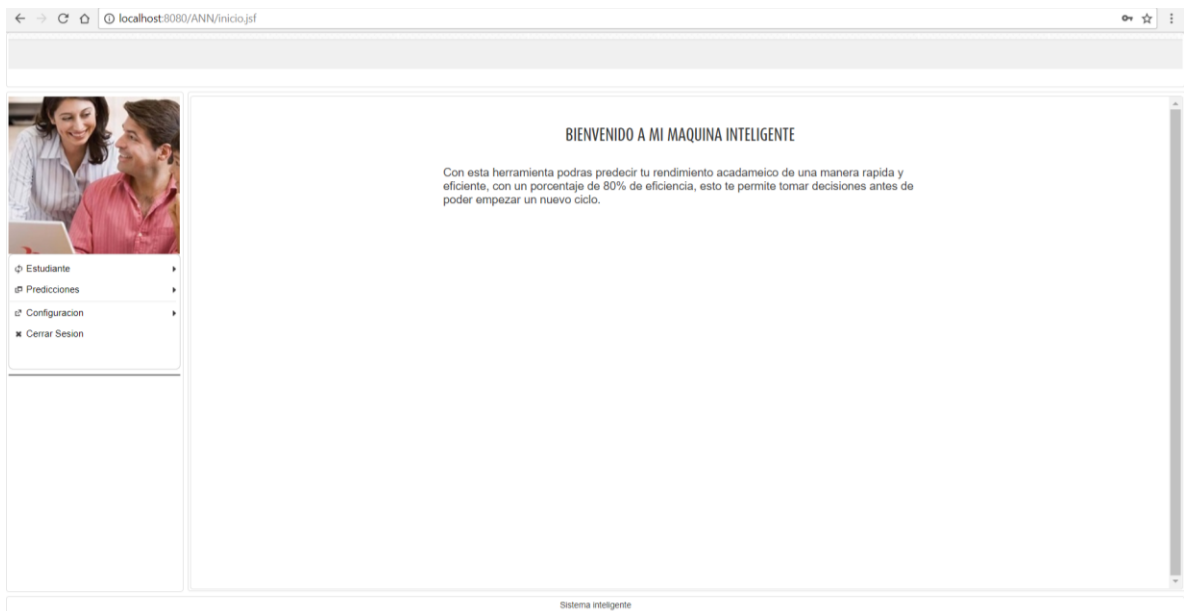
**Servidor de Base de datos:** Este nodo contiene el sistema administrador de base de datos. Interactúa con el nodo de servidor Web en su capa de acceso a datos (DAO).

### 4.2.5 Interfaces graficas del sistema

A continuación, se mostrará las interfaces graficas que se crearon para la solución propuesta.



**Figura 17: Login del aplicativo**



**Figura 18: Página principal del aplicativo web**

# CAPITULO V: RESULTADOS Y DISCUSIÓN

## 5.1 Resultados de entrenamiento de la red neuronal

Para poder entrenar nuestra red se hizo diversas pruebas, para empezar, se evaluó el rendimiento de nuestra red neuronal con la variedad de tipos de entradas que obtuvimos, la variación de nuestra arquitectura de la red neuronal, el error mínimo aceptado, u otros parámetros.

Las conclusiones se obtuvieron a partir del problema de que parámetros utilizar, esta elección es sumamente importante, si bien el algoritmo back propagation tiene una posibilidad alta de encontrar los pesos óptimos en nuestras capas, esta no siempre se da, por lo que fue necesario realizar muchas pruebas, hasta poder obtener los mejores resultados, en el peor de los casos tener una sola solución.

Se contó para el proceso de entrenamiento con un conjunto de registros de información de 40 estudiantes.

### Primer grupo de entrenamiento

Los primeros experimentos fueron realizados con el fin de poder generar el modelo predictivo utilizando seis de los primeros inputs posibles de los registros, tipo de curso, área del curso, nivel de agrado del curso, Horas de lectura diaria, horas de ocio diario.

Los resultados no fueron satisfactorios, el algoritmo back propagation no encontró correlación entre los inputs iniciales con las salidas esperadas, por lo que el entrenamiento de la red neuronal no pudo converger dentro de la cantidad máxima de iteraciones admitidas, como se muestra en la Tabla 4.

TABLA 7. RESULTADOS DE 1ER ENTRENAMIENTO

N	Parámetros de la red neuronal				Resultados		
	Neuronas por capa			Error mínimo cuadrático	Factor aprendizaje	Iteraciones	Tiempo (s)
	1°	2°	3°				
1°	6	6	2	0.001	0.05	Mayor a 5,000,000	Mas de 20 min.
2°	8	8	2	0.001	0.09	Mayor a 5,000,000	Mas de 20 min

Se cambio nuestro factor de aprendizaje en esas primeras dos pruebas de 0.5 a 0.9 así como la cantidad de neuronas, sin embargo, no se obtuvo mejores resultados, la red completa encuentra problemas.

Utilizando, un factor de aprendizaje mayor no se observó una mejora en el tiempo de aprendizaje. Esto se puede deber a varios aspectos tantos como los datos de entrada y los parámetros elegidos para nuestra red neuronal, por lo que se cambió los valores utilizados para el segundo grupo de entrenamiento.

Debido a esto no se pudo realizar una validación del modelo, ya que no culmino con el proceso de aprendizaje.

### Segundo grupo de entrenamiento

Ante los primeros resultados se optó por aplicar reducción de parámetros, y la selección de parámetro nuevos.

En el segundo grupo de experimentos se probó con otro conjunto de inputs iniciales, se incluyó el input horas de reunión semanal, y removiendo el input horas de ocio, cambiando así la estructura de el origen de datos a ser procesado.

En esta prueba se obtuvo resultados esperados, el algoritmo back se encontró el modelo predictivo con mejores resultados, para esto se realizó un total de 6, de las cuales mostramos las 3 que obtuvieron los mejores resultados, ver Tabla 5.

TABLA 8. RESULTADOS DE 2DO ENTRENAMIENTO

N	Parámetros de la red neuronal				Resultados		
	Neuronas por capa			Error mínimo cuadrático	Factor aprendizaje	Iteraciones	Tiempo (s)
	1°	2°	3°				
1°	8	8	2	0.002	0.05	210,586	110 s
2°	8	8	2	0.002	0.05	202,171	100 s
3°	8	8	2	0.002	0.05	200,519	90 s

En estas pruebas finales se utilizó los parámetros que nos generaron los mejores resultados, lo cual permitirá a realizar la validación de nuestro modelo y red neuronal.

El grupo de entrenamiento estuvo conformado por 40 estudiantes. Los estudiantes con aprendizaje excelente son 0, aprendizaje bueno son 10, aprendizaje regular: 27, aprendizaje deficiente: 8.

De estos 40 estudiantes, solo se obtuvo 33 patrones clasificados correctamente y 7 incorrectos, obteniendo un 0.825 de precisión en cuanto al modelo y los parámetros.

Los resultados de la técnica de Cross Validation es la siguiente, aprendizaje excelente (A), aprendizaje bueno (B), aprendizaje regular (C), aprendizaje deficiente (D), como muestra la Tabla.

TABLA 9. VALOR OBTENIDO VS ESTIMADO

		Valores obtenidos				Total
		A	B	C	D	
Valor estimado	A	0	0	0	0	<b>0</b>
	B	0	8	2	0	<b>10</b>
	C	0	2	22	3	<b>27</b>
	D	0	0	0	3	<b>3</b>
Total		<b>0</b>	<b>10</b>	<b>24</b>	<b>6</b>	<b>40</b>

## 5.2 Validación de la red neuronal

Para no obtener un sobreajuste de nuestra red neuronal se realizó este proceso de validación, obteniendo el mejor modelo y parámetros en base a las tareas de entrenamiento realizadas.

Con esta fase se pudo encontrar el mejor modelo y así como obtener el mejor grupo de parámetros para nuestra red neuronal. Para esto reservamos 10 estudiantes del total de nuestro conjunto de datos total, los estudiantes con aprendizaje excelente son 0, aprendizaje bueno son 3, aprendizaje regular son 4, aprendizaje deficiente son 3.

Con este grupo se obtuvo clasificados que los estudiantes con aprendizaje excelente son 0, aprendizaje bueno son 3, aprendizaje regular son 5, aprendizaje deficiente son 2.

De los resultados del proceso de validación, aprendizaje excelente (A), aprendizaje bueno (B), aprendizaje regular (C), aprendizaje deficiente (D).

		Valores obtenidos				Total
		A	B	C	D	
Valor estimado	A	0	0	0	0	<b>0</b>
	B	0	3	0	0	<b>3</b>
	C	0	0	4	0	<b>4</b>
	D	0	0	1	2	<b>3</b>
Total		<b>0</b>	<b>3</b>	<b>5</b>	<b>2</b>	<b>10</b>

TABLA 10. VALOR OBTENIDO VS ESTIMADO

De este grupo validación se obtuvo una precisión de 0.90, siendo superior a nuestra precisión de entrenamiento, la cual fue de 0.825.

Los resultados encontrados indican que este es el modelo más óptimo que se obtuvo, razón por la cual el proceso de entrenamiento se detuvo con ese modelo y parámetros.

### **Análisis e interpretación de resultados**

Las estructuras finales de las instancias se presentan en la Tabla 8, cada columna representa las variables del modelo.

id	Datos del curso			Datos del alumno		
	Tipo	Área	Agrado	Horas lectura	Horas practica	Horas reunión semanal
...	...	...	...	...	...	...

TABLA 11. ESTRUCTURA FINAL DE INSTANCIAS

Se descubrieron reglas de clasificación en los procesos de entrenamiento y validación, resumidas a continuación:

- Se observó que las horas de lectura influye mucho en cursos del área de ingeniería de software.
- En un curso como Inteligencia Artificial, con 3 a 4 horas de estudio se puede llegar a tener un promedio de 16.
- En los cursos de ingeniería de software el nivel de agrado no influye mucho.
- En los cursos de tipo matemática y operativa, si bien la práctica es muy importante, con 2 horas de lectura diaria se observó que se pueden aprobar dichos cursos.

### **5.3 Prueba de nuestra red neuronal**

El grupo de estudiantes para las pruebas de nuestro modelo está compuesto por 10 estudiantes, esta sección es de suma importancia ya que nos muestra el rendimiento real de nuestra red neuronal, los estudiantes para las pruebas fueron con aprendizaje excelente eran 0, aprendizaje bueno eran 3, aprendizaje regular eran 4, aprendizaje deficiente eran 3.

De los resultados generados se obtuvo la siguiente información.

Con este grupo se obtuvo clasificados que los estudiantes con aprendizaje excelente son 0, aprendizaje bueno son 3, aprendizaje regular son 5, aprendizaje deficiente son 2.

De los resultados del proceso de validación, aprendizaje excelente (A), aprendizaje bueno (B), aprendizaje regular (C), aprendizaje deficiente (D), ver Tabla 9.

		Valores obtenidos				Total
		A	B	C	D	
Valor estimado	A	0	0	0	0	<b>0</b>
	B	0	3	0	0	<b>3</b>
	C	0	0	4	0	<b>4</b>
	D	0	0	2	1	<b>3</b>



Total	0	3	6	1	10
-------	---	---	---	---	----

TABLA 12. VALOR OBTENIDO VS ESTIMADO

Estos resultados poseen una precisión de 0.80, la cual es superior a nuestra fase de entrenamiento y cercana a la validación.

Los resultados de nuestro trabajo nos indican que el grado de confiabilidad que tiene actualmente nuestra clasificación, cabe resaltar que esto puede mejorar con la obtención de una mayor cantidad de conjunto de datos.

	ENTRADA	SALIDA	RESULTADO
1	Aprendizaje bueno	Aprendizaje bueno	bien
2	Aprendizaje regular	Aprendizaje regular	bien
3	Aprendizaje deficiente	Aprendizaje deficiente	bien
4	Aprendizaje regular	Aprendizaje deficiente	mal
5	Aprendizaje regular	Aprendizaje regular	bien
6	Aprendizaje regular	Aprendizaje regular	bien
7	Aprendizaje regular	Aprendizaje deficiente	mal
8	Aprendizaje bueno	Aprendizaje bueno	bien
9	Aprendizaje regular	Aprendizaje regular	bien
10	Aprendizaje regular	Aprendizaje regular	bien

TABLA 13. RESULTADOS DE PROCESO DE PRUEBAS

#### 5.4 Resultados de aplicativo web

El aplicativo construido tiene como finalidad poder predecir el rendimiento de tendrá un estudiante en cualquiera de sus cursos registrados, para esto el aplicativo mostrará los resultados generados de una manera amigables.

The screenshot shows a web browser at the URL `localhost:8080/ANN/estudiante/prediccion.jsf?idCurso=7`. The application interface is titled "PREDECIR RENDIMIENTO ACADEMICO".

**Informacion del Curso:**

- Ingrese un curso:
- Area del curso:
- Tipo del curso:
- Nivel de agrado:

**Organizacion del Curso:**

- Horas de Lectura:
- Horas de la practica:
- Horas de reunion semanal:

Buttons: **Realizar prediccion** (red), **Limpiar** (red)

**PREDICCION GENERADA:**

- Curso:
- Fecha:
- Prediccion: **Aprendizaje bueno** (yellow box)

Footer: Sistema inteligente

**Figura 19: Presentación de una predicción de rendimiento por aplicativo**

## Conclusiones

La información autorregulada de los estudiantes permite generar modelos [8], así como esta investigación demuestra el uso de la información de planificación estudiantil para la generación de modelos de clasificación.

Se encontró en [1], y [2] se utilizaron grandes cantidades de información contenidas en grandes sistemas, en esta investigación no fue necesaria contar con gran cantidad de datos para poder obtener una precisión más que aceptable en las predicciones, sino poseer información que contar mucho valor.

La necesidad de poseer diferentes tipos de datos es sumamente importante, estos pueden estar contenidos en diferentes fuentes de datos tal como se indicó en [5]. Los centros de estudios deben preocuparse por administrar y generar toda la información posible para futuros trabajos de investigación.

Esta investigación demostró el uso de las redes neuronales artificiales para poder generar modelos de clasificación con una confiabilidad del 80%.

## REFERENCIA BIBLIOGRAFICAS

- García, H. y Palacios, R. (2000). Factores condicionantes del aprendizaje en lógico matemático (Tesis de grado de Magíster). Universidad San Martín de Porras, Lima, Perú.
- Trujillo, J.; Iglesias, W. (2010). Sueño y asignación de tiempo entre los estudiantes universitarios: El Caso de la Universidad del Atlántico. Recuperado de <http://www.scielo.org.co/>.
- Pérez, V.; Valenzuela, M.; Díaz, A.; González, J.; Núñez, J. (2013). Learning difficulties in first year university students.
- Navarro, C.; Molina, A.; Redondo, M. (2012). Evaluation framework for m-learning systems: Current situation and proposal.
- Blumenfeld, P.C. (1992). Classroom learning and motivation: Clarifying and expanding goal theory. *Journal of Educational Psychology* 84 (3): 272-281.
- Lamb, R.; Annetta, L.; Vallett D.; D. Sadler T. (2014). Cognitive diagnostic like approaches using neural-network analysis of serious educational videogames. *Computers & Education*.
- Hashmia Hamsa, Simi Indiradevi, Jubilant j. Kizhakkethottam (2016). Student Academic Performance Prediction Model Using Decision Tree and Fuzzy Genetic Algorithm. *Procedia Technology*.
- S. M. Merchán, Miembro de IEEE y J. A. Duarte. (2016). Analysis of Data Mining Techniques for Constructing a Predictive Model for Academic Performance. *IEEE Latin America Transactions*.
- Krina Parmar, Dineshkumar Vaghela y Priyanka Sharma (2015). Performance prediction of Students using distributed data mining. Coimbatore, India.
- Mvurya Mgala, Audrey Mbogho (2015). Data-Driven Intervention-Level Prediction Modeling For Academic Performance. *Seventh International Conference on Information and Communication Technologies and Development*.
- Camilo E. López G., Elizabeth León Guzmán and Fabio A. González (2015). A Model to Predict Low Academic Performance at a Specific Enrollment Using. *IEEE Revista Iberoamericana de Tecnologías del Aprendizaje*.

- Rui Wang, Gabriella Harari, Peilin Hao, Xia Zhou, y Andrew T. Campbell (2015). How Smartphones Can Assess and Predict Academic Performance of College Students. ACM International Joint Conference on Pervasive and Ubiquitous Computing.
- Abelardo Pardo, Negin Mirriahi, Roberto Martínez Maldonado. (2016). Generating Actionable Predictive Models of Academic Performance. Sixth International Conference on Learning Analytics & Knowledge.
- Abelardo Pardo, Feifei Han, and Robert A. Ellis. (2017). Combining university student self-regulated learning indicators and engagement with online learning events to predict academic performance. IEEE Transactions On Learning Technologies, Manuscript ID.
- S. Ikbali, A. Tamhane, B. Sengupta, M. Chetlur, S. Ghosh, J. Appleton. (2015). On early prediction of risks in academic performance for students. IBM Journal of Research and Development.
- J.C. Cortés, J. M. Colmenar, J. I. Hidalgo, A. Sánchez-Sánchez, F.J. Santonja, R.J. Villanueva. (2016). Modeling and predicting the Spanish Bachillerato academic results over the next few years using a random network model. Physica A: Statistical Mechanics and its Applications.
- Lindvall, C. M., y Cox, R. C.: Evaluation as a tool in Curriculum Development. Rand McNally. Chicago. 1970; P. 79
- García Hoz, V.: Educación personalizada. Instituto de Pedagogía. Madrid, 1970: PP. 116 y ss.
- Marco Sobrevilla Cabezudo (2010), Implementación de Redes Neuronales para mejorar el Análisis de la Probabilidad de Ocurrencia de Sismos en el Perú, UNMSM, Tesis de Pregrado, Lima-Perú.
- Xavier Basogain Olabe, Redes Neuronales Artificiales y sus Aplicaciones, <http://ocw.ehu.es/enseñanzas-tecnicas/redes-neuronales-artificiales-y-sus-aplicaciones/contenidos/pdf/libro-del-curso>, (13 de abril del 2012)
- Effer Apaza, Alberto Huamán, Factores determinantes que inciden en la deserción de los estudiantes universitarios, <http://revistas.concytec.gob.pe/pdf/au/v2n1/a06v2n1.pdf>, (31 de Mayo del 2014)
- Damián Jorge Matich, Redes Neuronales: Conceptos básicos y Aplicaciones, [http://www.frro.utn.edu.ar/repositorio/catedras/quimica/5\\_anio/orientadora1/monografias/matich-redesneuronales.pdf](http://www.frro.utn.edu.ar/repositorio/catedras/quimica/5_anio/orientadora1/monografias/matich-redesneuronales.pdf), (12 de setiembre del 2012)

- Daniel Numberger, Aplicaciones Industriales de Redes Neuronales,  
[http://www.numberger.de/studium/aplicaciones\\_neuro.pdf](http://www.numberger.de/studium/aplicaciones_neuro.pdf), (17 de Junio del 2013)
- José Luis Calderón O., Redes Neuronales Artificiales: teoría y Diseño,  
<http://www.slideshare.net/mentelibre/redes-neuronales-artificiales-historia-y-teoria> ,  
 (26 de abril del 2012)
- Eybi Gil Zavaleta y Edith Rodríguez Collas (2010), Sistema de pronóstico de la demanda de productos farmacéuticos basado en redes neuronales, UNMSM, Tesis de Pregrado, Lima-Perú.
- Tonconi J. Factores que influyen en el rendimiento académico y la deserción de los estudiantes de la facultad de Ingeniería Económica de la UNA-PUNO, periodo 2009. Cuadernos de Educación y Desarrollo [Internet]. 2010 [citado 3 feb 2013];2(11):[aprox. 27 p.]. Disponible en: <http://www.eumed.net/rev/ced/11/jtq.htm>
- Requena, F. (1998). Género, redes de amistad y rendimiento académico. Universidad de Santiago de Compostela. Departamento de Sociología. Extraído el 8 de septiembre de 2008 desde <http://ddd.uab.es/pub/papers/02102862n56p233.pdf>
- Chayña M. Estilos de Aprendizaje y su Relación con el Rendimiento Académico en los Estudiantes de la FACE-UANCV. 2007. Recuperado el 21 de Diciembre de 2007 del sitio Web <http://www.monografias.com/trabajos44/estilos-aprendizaje/estilos-aprendizaje.shtml>
- Leonardo M. Reyneri, Enrica Filippi (1991). An Analysis on the Performance of Silicon Implementations of Backpropagation Algorithms for Artificial Neural Networks
- S. M. Merchán, Member, IEEE, J. A. Duarte (2016) .Analysis of Data Mining Techniques for Constructing a Predictive Model for Academic Performance
- T. Fawcett. Gráficos Roc: Notas y consideraciones prácticas para los investigadores. Aprendizaje de la máquina, 31: 1 {38, 2004.
- Santhosh Nagulan, Jegadheeswaran Selvaraj, Amarkarthik Arunachalam y Kaushik Sivanandam (2017). Performance of artificial neural network in prediction of heave displacement for non-buoyant type wave energy converter